

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF APPLIED SCIENCES



Probability and Statistics for Engineers

Report Assignment Report

Report Assignment Report of Probability and Statistics for Engineers

Advisor(s): TS. Trần Huyền Châu

Student(s): Lê Đình Quân 2412887

Nguyễn Trí Tú 2413858

Ngô Châu Tuấn Anh 2410103

Đoàn Duy Phúc 2412702

Phạm Hoàng Minh Anh 2410137

Class: L11 - NHÓM 4 - HK252

HO CHI MINH CITY, MAY 2026

DANH SÁCH THÀNH VIÊN VÀ PHÂN CÔNG NHIỆM VỤ

Students	SSID	Faculty	Tasks
Lê Đình Quân	2412887	Computer Science & Engineering	Data Processing
Nguyễn Trí Tú	2413858	Computer Science & Engineering	Data Processing
Ngô Châu Tuấn Anh	2410103	Mechanical Engineering	Report Writing
Đoàn Duy Phúc	2412702	Mechanical Engineering	Model Evaluation
Phạm Hoàng Minh Anh	2410137	Mechanical Engineering	Model Building

Contents

1	GIỚI THIỆU CHUNG	9
1.1	GIỚI THIỆU CHUNG	10
1.1.1	Đặt vấn đề	10
1.1.2	Mục tiêu nghiên cứu	10
1.1.3	Đối tượng và Phạm vi nghiên cứu	11
1.1.3.1	Đối tượng nghiên cứu	11
1.1.3.2	Phạm vi nghiên cứu	11
1.1.4	Phương pháp nghiên cứu	11
1.1.5	Cấu trúc của bài báo cáo	12
1.2	Kiến thức cần chuẩn bị	13
1.2.1	Dữ liệu, biến định lượng và biến định tính	13
1.2.2	Thống kê mô tả	13
1.2.2.1	Trung bình	14
1.2.2.2	Trung vị	14
1.2.2.3	Phương sai và độ lệch chuẩn	15
1.2.3	Tứ phân vị, IQR và ngoại lai	16
1.2.4	Histogram và boxplot	16
1.2.5	Scatter plot và tương quan Pearson	17
1.2.6	Hồi quy tuyến tính	18
1.2.6.1	Hồi quy tuyến tính đơn	18
1.2.6.2	Hồi quy tuyến tính bội	19
1.2.7	Đánh giá mô hình hồi quy: phần dư, R^2 , adjusted R^2 , p -value và F -statistic	20
1.2.8	Một số hàm R thường dùng	21
1.2.9	Mô tả các biến số được sử dụng trong chương 3	23
2	Hoạt động 2 - THỐNG KÊ MÔ TẢ VÀ TRỰC QUAN HÓA DỮ LIỆU	26



2.1	Thông số cần chuẩn bị	27
2.1.1	Thống kê mô tả	27
2.1.1.1	Các đặc trưng đo lường xu hướng trung tâm và độ phân tán	27
2.1.2	Mô hình tuyến tính bội	28
2.2	Phân tích dữ liệu và xây dựng mô hình	29
2.2.1	Đọc dữ liệu	29
2.2.2	Làm sạch dữ liệu	29
2.2.3	Làm rõ dữ liệu	30
2.2.4	Mô hình hồi quy tuyến tính	42
2.2.5	Dự báo điểm học sinh mới	43
3	Hoạt động 3 - THỐNG KÊ VÀ PHÂN TÍCH THÔNG SỐ HIỆU NĂNG PHẦN CỨNG MÁY TÍNH	46
3.1	Tổng quan về tập tài liệu	47
3.1.1	Mô tả tập dữ liệu	47
3.2	Phân tích dữ liệu	47
3.2.1	Đọc dữ liệu	47
3.2.2	Thống kê mô tả	48
3.2.2.1	Thống kê biến liên tục	48
3.2.3	Thống kê biến rời rạc	52
3.3	Đồ thị	53
3.3.1	Tiền xử lý dữ liệu	53
3.3.2	Đồ thị Scatters	54
3.3.3	Đồ thị Histogram	56
3.3.4	Đồ thị Boxplot	58
3.4	Mô hình hồi quy tuyến tính	59
3.4.1	Kiểm định mối tương quan	59
3.4.2	Lọc giá trị ngoại lai	60
3.5	Xây dựng mô hình hồi quy tuyến tính dự báo PRP	61
3.6	Dự báo hiệu suất và so sánh	63
3.6.1	Dự báo điểm hiệu suất máy mới	63
3.6.2	So sánh hiệu suất PRP thực tế và dự báo	64
4	KẾT LUẬN VÀ KIẾN NGHỊ	67

List of Figures

1.2.1 Phân biệt biến định lượng và biến định tính	13
1.2.2 Minh họa giá trị trung bình trên trục số	14
1.2.3 Minh họa phương sai và độ lệch chuẩn	15
1.2.4 Minh họa boxplot, IQR và điểm ngoại lai	16
1.2.5 Minh họa histogram của một mẫu lệch phải	17
1.2.6 Minh họa scatter plot với xu hướng tương quan thuận	18
1.2.7 Minh họa đường hồi quy tuyến tính và phần dư	19
1.2.8 Minh họa residual plot với phần dư phân tán quanh 0	20
1.2.9 Minh họa biểu đồ giá trị thực tế so với giá trị dự báo	21
1.2.10 Một luồng thao tác điển hình trong R cho phân tích và hồi quy	23
2.1.1 Mối quan hệ giữa biến X và Y trong hồi quy tuyến tính	29
2.2.1 Kết quả sau khi lọc	30
2.2.2 Kết quả sau khi print	31
2.2.3 Kết quả thống kê của biến định lượng	32
2.2.4 Kết quả thống kê của biến định tính	33
2.2.5 Biểu đồ Histogram thể hiện phân phối điểm học kỳ 1 (G1), học kỳ 2 (G2) và điểm cuối kỳ (G3)	34
2.2.6 Biểu đồ Histogram thể hiện phân phối số ngày nghỉ học (absences)	35
2.2.7 Biểu đồ Histogram thể hiện phân phối số lần trượt môn (failures)	35
2.2.8 Biểu đồ Boxplot thể hiện sự phân bố điểm G3 theo thời gian tự học (trái) và số lần trượt môn (phải)	37
2.2.9 Biểu đồ Boxplot thể hiện sự phân bố điểm G3 theo việc học thêm (trái) và giới tính (phải)	38
2.2.10 Biểu đồ Scatter plot thể hiện mối quan hệ giữa số ngày nghỉ học (absences) và điểm cuối kỳ (G3)	40

2.2.11 Biểu đồ Scatter plot thể hiện mối quan hệ giữa điểm học kỳ 1 (G1) và điểm cuối kỳ (G3)	41
2.2.12 Biểu đồ Scatter plot thể hiện mối quan hệ giữa điểm học kỳ 2 (G2) và điểm cuối kỳ (G3)	41
2.2.13 Kết quả mô hình hồi quy tuyến tính	42
2.2.14 Kết quả dự đoán điểm G3	44
2.2.15 Mô hình hồi quy thể hiện mối quan hệ giữa điểm thực tế và dự báo	45
3.1.1 Thống kê số biến và giá trị quan trắc của file machine.csv	47
3.2.1 Kết quả sau khi quét số lượng dữ liệu khuyết của file Main_data	48
3.2.2 Bảng dữ liệu sau khi thêm tên cột dữ liệu (6 dòng đầu)	48
3.2.3 Kết quả thống kê số lượng máy tính theo hãng sản xuất	52
3.3.1 Kết quả sau khi xoay cấu trúc dữ liệu	54
3.3.2 Biểu đồ scatter giữa PRP và các thông số phần cứng	55
3.3.3 Đồ thị Histogram của 7 biến sau chọn lọc	57
3.3.4 Đồ thị Boxplot của 7 biến sau chọn lọc	58
3.4.1 Hệ số tương quan giữa các biến với nhau	59
3.4.2 Tập dữ liệu sau khi lọc giá trị ngoại lai	61
3.5.1 Kết quả chi tiết của mô hình hồi quy tuyến tính	62
3.6.1 Kết quả dự báo PRP của mô hình	64
3.6.2 Mô hình hồi quy thể hiện mối quan hệ giữa điểm thực tế và dự báo	65

List of Tables

1.2.1 Một số hàm R thường dùng trong phân tích dữ liệu	22
1.2.2 Danh sách các biến liên quan đến hiệu năng tổng quát	25
1.2.3 Danh sách các biến liên quan đến hiệu năng tổng quát trong bộ Computer Hard- ware Dataset ở chương 3	25
3.2.1 Bảng thống kê biến liên tục	50

Chương 1

GIỚI THIỆU CHUNG

1.1 GIỚI THIỆU CHUNG

1.1.1 Đặt vấn đề

Trong kỷ nguyên công nghiệp 4.0, dữ liệu được ví như ”dầu mỏ” của nền kinh tế số. Việc thu thập, lưu trữ và phân tích dữ liệu đã trở thành một phần tất yếu trong mọi lĩnh vực từ kỹ thuật, kinh tế đến giáo dục. Tuy nhiên, lượng dữ liệu khổng lồ tự thân nó không mang lại giá trị định lượng nếu thiếu đi các phương pháp xử lý và phân tích khoa học để rút trích thông tin và tri thức.

Theo Montgomery và Runger^[7] trong tác phẩm *Applied Statistics and Probability for Engineers*, thống kê là khoa học về việc thu thập, tổ chức, phân tích và giải thích dữ liệu. Đối với các kỹ sư và nhà nghiên cứu, tư duy thống kê không chỉ giúp hiểu rõ các quá trình biến thiên tự nhiên mà còn cung cấp bộ công cụ mạnh mẽ để đưa ra các quyết định dựa trên bằng chứng thực tế thay vì cảm tính. Sự biến thiên (variability) là một đặc tính cố hữu của mọi hệ thống thực tế; do đó, xác suất thống kê đóng vai trò là cầu nối giữa các mô hình toán học lý tưởng và sự phức tạp của thế giới thực.

Bên cạnh các phương pháp thống kê truyền thống, sự bùng nổ của sức mạnh tính toán đã thúc đẩy sự phát triển của Học máy Thống kê (Statistical Learning). Như James và cộng sự^[6] đã định nghĩa trong *An Introduction to Statistical Learning*, học máy thống kê cung cấp một tập hợp các công cụ để hiểu các tập dữ liệu lớn và phức tạp. Nó kết hợp giữa thống kê toán học và các thuật toán máy tính để xây dựng các mô hình dự báo hoặc mô hình mô tả mối quan hệ giữa các biến số.

Trong bối cảnh đó, việc thực hiện đề tài phân tích dữ liệu dựa trên các tập dữ liệu thực tế như hiệu năng phần cứng máy tính và kết quả học tập của học sinh là vô cùng cần thiết. Điều này không chỉ giúp củng cố kiến thức lý thuyết về xác suất thống kê mà còn rèn luyện kỹ năng thực hành trên các công cụ phân tích hiện đại^[2].

1.1.2 Mục tiêu nghiên cứu

Đề tài này được thực hiện với các mục tiêu chính sau đây:

- **Về mặt lý thuyết:** Hệ thống hóa các kiến thức cơ bản về thống kê mô tả, xác suất và các mô hình hồi quy. Tìm hiểu sâu về các nguyên lý đằng sau việc ước lượng tham số và kiểm định giả thuyết^[7].
- **Về mặt công cụ:** Sử dụng thành thạo ngôn ngữ lập trình R - một tiêu chuẩn công nghiệp trong phân tích thống kê^[2]. Việc nắm vững cách xử lý dữ liệu (data wrangling) và trực quan hóa (visualization) là một phần quan trọng của mục tiêu này.

- **Về mặt thực tiễn:**

- Phân tích mối liên hệ giữa các thông số kỹ thuật (như bộ nhớ đệm, dung lượng bộ nhớ) và hiệu năng thực tế của các hệ thống máy tính.
- Đánh giá các yếu tố ảnh hưởng đến kết quả học tập của học sinh (điểm G1, G2, G3) thông qua thống kê mô tả và các chỉ số đo lường xu hướng trung tâm.
- Xây dựng các mô hình dự báo nhằm đưa ra những nhận định có giá trị cho việc tối ưu hóa hiệu suất hoặc cải thiện chất lượng giáo dục^[6].

1.1.3 Đối tượng và Phạm vi nghiên cứu

1.1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài bao gồm hai tập dữ liệu:

1. **Tập dữ liệu Hiệu năng Phần cứng (Computer Hardware Dataset):** Bao gồm các quan sát với các thuộc tính như chu kỳ máy (MYCT), bộ nhớ tối thiểu/tối đa (MMIN/MMAX), bộ nhớ đệm (CACH), và hiệu suất công bố (PRP).
2. **Tập dữ liệu Kết quả Học tập (Student Performance Dataset):** Tập trung vào điểm số của học sinh qua các giai đoạn (G1, G2, G3) và các yếu tố xã hội, gia đình liên quan.

1.1.3.2 Phạm vi nghiên cứu

- **Phạm vi nội dung:** Tập trung vào thống kê mô tả (Descriptive Statistics), phân tích tương quan (Correlation Analysis) và hồi quy tuyến tính (Linear Regression).
- **Phạm vi công cụ:** Toàn bộ quá trình tính toán và vẽ đồ thị được thực hiện trên môi trường RStudio, sử dụng các thư viện phổ biến như ggplot2, dplyr, và tidyverse.

1.1.4 Phương pháp nghiên cứu

Để giải quyết bài toán đặt ra, đề tài áp dụng quy trình nghiên cứu khoa học dữ liệu chuẩn mực:

1. Thu thập và Tiền xử lý dữ liệu: Dữ liệu từ các nguồn công khai được làm sạch, xử lý các giá trị thiếu (missing values) và định dạng lại để phù hợp với các thuật toán phân tích. Việc xoay cấu trúc dữ liệu (pivoting bằng `pivot_longer`) cũng được áp dụng để phục vụ cho mục đích trực quan hóa đa biến.

2. Thống kê mô tả và Trực quan hóa: Sử dụng các đại lượng như trung bình (Mean), trung vị (Median), phương sai (Variance) và độ lệch chuẩn (Standard Deviation) để tóm tắt các đặc tính

của dữ liệu. Các loại biểu đồ như Histogram, Boxplot và Scatter plot được sử dụng để phát hiện các xu hướng và các giá trị ngoại lai (outliers)^[2].

3. Phân tích tương quan và Xây dựng mô hình: Sử dụng hệ số tương quan để xác định mức độ mật thiết giữa các biến số. Sau đó, mô hình hồi quy tuyến tính được xây dựng để định lượng mối quan hệ này. Công thức tổng quát của mô hình hồi quy đơn biến thường có dạng:

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (1.1.1)$$

Trong đó Y là biến phụ thuộc, X là biến độc lập, β_0, β_1 là các hệ số hồi quy và ϵ là sai số ngẫu nhiên^[7].

1.1.5 Cấu trúc của bài báo cáo

Bài báo cáo được chia thành các chương như sau:

- **Chương 1: Giới thiệu chung.** Trình bày lý do chọn đề tài, mục tiêu, đối tượng và phương pháp nghiên cứu. Trình bày cơ sở lý thuyết và các lệnh, hàm thông dụng trong R.
- **Chương 2: Thống kê mô tả và Phân tích sơ bộ.** Tập trung vào việc mô tả các đặc trưng của tập dữ liệu học sinh và phân cứng máy tính thông qua các chỉ số thống kê và biểu đồ.
- **Chương 3: Phân tích sâu và Xây dựng mô hình dự báo.** Áp dụng các phương pháp thống kê suy diễn và học máy để giải quyết các giả thuyết nghiên cứu.
- **Chương 4: Kết luận và Kiến nghị.** Tóm tắt các kết quả đạt được và đề xuất các hướng phát triển tương lai.

1.2 Kiến thức cần chuẩn bị

1.2.1 Dữ liệu, biến định lượng và biến định tính

Trong thống kê, dữ liệu thường được tổ chức dưới dạng bảng. Mỗi hàng ứng với một quan sát, còn mỗi cột ứng với một biến. Biến định lượng là biến nhận giá trị số và có thể thực hiện các phép tính số học như trung bình, phương sai hoặc độ lệch chuẩn. Ngược lại, biến định tính dùng để phân loại đối tượng theo nhóm, chẳng hạn giới tính, loại máy, hãng sản xuất hoặc trạng thái có học thêm hay không^[2;7].

Trong bộ Computer Hardware Dataset, các biến như MYCT, MMIN, MMAX, CACH, CHMIN, CHMAX và PRP là các biến định lượng. Trong đó, PRP là hiệu năng công bố của máy tính và thường được xem là biến phụ thuộc khi xây dựng mô hình hồi quy. Các biến như VendorName hoặc ModelName mang tính phân loại nhiều hơn là đo lường số học^[3;13].

Trong bộ Student Performance Dataset, các biến G1, G2, G3 và absences là biến định lượng. Các biến như sex hoặc paid là biến định tính. Một số biến như studytime và failures tuy được mã hóa bằng số, nhưng trong nhiều phân tích có thể được xem như biến thứ bậc hoặc biến nhóm, tùy theo mục tiêu phân tích^[1;14].




Figure 1.2.1: Phân biệt biến định lượng và biến định tính

Việc xác định đúng kiểu biến là bước quan trọng trước khi phân tích. Với biến định lượng, ta có thể dùng histogram, boxplot, scatter plot, hệ số tương quan và hồi quy. Với biến định tính, ta thường dùng bảng tần số, biểu đồ cột hoặc boxplot theo nhóm. Nếu xác định sai kiểu dữ liệu, kết quả phân tích có thể bị diễn giải sai, đặc biệt khi đưa biến vào mô hình hồi quy.

1.2.2 Thống kê mô tả

Thống kê mô tả là nhóm phương pháp dùng để tóm tắt dữ liệu thông qua các đại lượng đặc trưng và biểu đồ trực quan. Thay vì đọc toàn bộ dữ liệu thô, người phân tích có thể dùng trung bình, trung vị, phương sai, độ lệch chuẩn, tứ phân vị, histogram và boxplot để nắm được xu hướng trung tâm, mức độ phân tán và hình dạng phân phối của dữ liệu^[2;7].

1.2.2.1 Trung bình

Trung bình mẫu là đại lượng thể hiện giá trị đại diện theo nghĩa cân bằng số học của dữ liệu. Với mẫu gồm n quan sát $x_1, x_2, \dots, x_n$, trung bình mẫu được tính bởi:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Ví dụ, với dãy số:

2, 4, 6, 8, 10,

ta có:

$$\bar{x} = \frac{2 + 4 + 6 + 8 + 10}{5} = 6.$$




Figure 1.2.2: Minh họa giá trị trung bình trên trục số

Trong bài toán phần cứng, trung bình giúp mô tả mức hiệu năng hoặc mức cấu hình trung bình của các máy. Trong bài toán điểm số, trung bình của G1, G2 và G3 cho biết mức điểm chung của học sinh ở từng giai đoạn.

1.2.2.2 Trung vị

Trung vị là giá trị nằm ở giữa dữ liệu sau khi sắp xếp theo thứ tự tăng dần. Nếu số quan sát là lẻ, trung vị là giá trị ở vị trí trung tâm. Nếu số quan sát là chẵn, trung vị thường được lấy bằng trung bình cộng của hai giá trị ở giữa^[2].

Ví dụ, với dãy:

1, 2, 3, 100, 101,

trung bình là:

$$\bar{x} = 41.4,$$

nhưng trung vị là:

$$Me = 3.$$

Ví dụ này cho thấy trung bình có thể bị kéo lệch bởi các giá trị rất lớn hoặc rất nhỏ, trong khi trung vị phản ánh tốt hơn vị trí trung tâm của phần lớn dữ liệu. Điều này đặc biệt hữu ích khi phân tích các biến có phân phối lệch phải như PRP, MMAX, CACH hoặc absences.

1.2.2.3 Phương sai và độ lệch chuẩn

Phương sai và độ lệch chuẩn dùng để đo mức độ phân tán của dữ liệu quanh giá trị trung bình. Phương sai mẫu được tính bởi:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Độ lệch chuẩn là căn bậc hai của phương sai:

$$s = \sqrt{s^2}.$$

Xét hai dãy:

$$A = \{5, 6, 7, 8, 9\}, \quad B = \{1, 3, 7, 11, 13\}.$$

Hai dãy đều có trung tâm gần 7, nhưng dãy B phân tán rộng hơn dãy A . Vì vậy, độ lệch chuẩn của B lớn hơn độ lệch chuẩn của A .

Hai dãy có trung tâm gần nhau nhưng độ phân tán khác nhau




Figure 1.2.3: Minh họa phương sai và độ lệch chuẩn

Trong bộ Computer Hardware Dataset, độ lệch chuẩn lớn của PRP cho thấy hiệu năng máy tính khác nhau đáng kể giữa các quan sát. Trong bộ Student Performance Dataset, độ lệch chuẩn của G3 cho biết mức độ phân hóa điểm cuối kỳ giữa các học sinh.

1.2.3 Tứ phân vị, IQR và ngoại lai

Tứ phân vị chia dữ liệu đã sắp xếp thành bốn phần. Ba tứ phân vị thường dùng là Q_1 , Q_2 và Q_3 , trong đó Q_2 chính là trung vị. Khoảng tứ phân vị được định nghĩa là:

$$IQR = Q_3 - Q_1.$$

IQR biểu diễn độ rộng của 50% dữ liệu trung tâm. So với khoảng biến thiên từ giá trị nhỏ nhất đến lớn nhất, IQR ít bị ảnh hưởng bởi các giá trị quá bất thường^[5;12].

Một quy tắc phổ biến để phát hiện ngoại lai là quy tắc Tukey:

$$\text{Lower fence} = Q_1 - 1.5IQR,$$

$$\text{Upper fence} = Q_3 + 1.5IQR.$$

Những quan sát nằm ngoài hai ngưỡng này thường được xem là ngoại lai^[8;12].

Ví dụ, với dãy:

2, 3, 4, 5, 6, 7, 8, 30,

giá trị 30 có thể được xem là ngoại lai vì lớn hơn rõ rệt so với phần còn lại của dữ liệu.




Figure 1.2.4: Minh họa boxplot, IQR và điểm ngoại lai

Trong dữ liệu phân cứng, ngoại lai có thể xuất hiện ở các máy có hiệu năng rất cao hoặc bộ nhớ rất lớn. Trong dữ liệu điểm số, ngoại lai có thể xuất hiện ở biến absences khi một vài học sinh nghỉ học nhiều hơn hẳn phần còn lại.

1.2.4 Histogram và boxplot

Histogram là biểu đồ mô tả phân phối của một biến định lượng bằng cách chia trục giá trị thành nhiều khoảng và đếm số quan sát rơi vào mỗi khoảng. Histogram giúp nhận biết dữ liệu tập trung ở đâu, có lệch trái hay lệch phải, có nhiều đỉnh hay không và có dấu hiệu ngoại lai hay không^[2;8].




Figure 1.2.5: Minh họa histogram của một mẫu lệch phải

Boxplot là biểu đồ hộp thể hiện trung vị, tứ phân vị, IQR và các điểm ngoại lai. Khi cần so sánh nhiều nhóm, boxplot đặc biệt hữu ích vì có thể đặt nhiều hộp cạnh nhau trên cùng một hệ trục^[8;12].

Trong bộ Student Performance Dataset, boxplot có thể dùng để so sánh điểm G3 theo giới tính, số lần trượt môn, thời gian học hoặc việc học thêm. Trong bộ Computer Hardware Dataset, boxplot giúp phát hiện PRP, MMAX hoặc CACH có phân phối lệch mạnh và có ngoại lai hay không.

1.2.5 Scatter plot và tương quan Pearson

Scatter plot là biểu đồ phân tán dùng để biểu diễn các cặp quan sát (x_i, y_i) . Mỗi điểm trên hình ứng với một quan sát. Biểu đồ này cho phép nhận biết xu hướng quan hệ giữa hai biến định lượng, chẳng hạn quan hệ thuận, quan hệ nghịch, quan hệ tuyến tính hoặc quan hệ phi tuyến^[7;8].




Figure 1.2.6: Minh họa scatter plot với xu hướng tương quan thuận

Hệ số tương quan Pearson đo mức độ liên hệ tuyến tính giữa hai biến định lượng:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Giá trị r nằm trong khoảng $[-1, 1]$. Nếu $r > 0$, hai biến có xu hướng tăng cùng nhau. Nếu $r < 0$, một biến tăng thì biến còn lại có xu hướng giảm. Nếu $|r|$ càng gần 1, mối liên hệ tuyến tính càng mạnh^[7;9].

Trong bộ Computer Hardware Dataset, PRP thường được quan tâm khi phân tích tương quan với MYCT, MMIN, MMAX, CACH, CHMIN và CHMAX. Trong bộ Student Performance Dataset, tương quan giữa G1, G2 và G3 có ý nghĩa quan trọng vì điểm ở các giai đoạn trước thường liên quan trực tiếp đến điểm cuối kỳ.

1.2.6 Hồi quy tuyến tính

Hồi quy tuyến tính là phương pháp mô hình hóa mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập. Mục tiêu của hồi quy là mô tả xu hướng trung bình của biến phụ thuộc khi các biến giải thích thay đổi, đồng thời có thể dùng mô hình để dự báo^[4;6;7].

1.2.6.1 Hồi quy tuyến tính đơn

Mô hình hồi quy tuyến tính đơn có dạng:

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

Trong đó, Y là biến phụ thuộc, X là biến độc lập, β_0 là hệ số chặn, β_1 là hệ số góc và ε là sai số ngẫu nhiên. Giá trị dự báo từ mô hình là:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X.$$

Các hệ số hồi quy thường được ước lượng bằng phương pháp bình phương tối thiểu. Ý tưởng của phương pháp này là chọn đường thẳng sao cho tổng bình phương sai khác giữa giá trị thực tế và giá trị dự báo là nhỏ nhất:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$




Figure 1.2.7: Minh họa đường hồi quy tuyến tính và phần dư

Các điểm đen là dữ liệu quan sát được. Đường màu xanh là đường hồi quy. Các đoạn nét đứt thể hiện phần dư, tức là sai khác giữa giá trị thực tế và giá trị mô hình dự báo.

1.2.6.2 Hồi quy tuyến tính bội

Khi có nhiều biến giải thích, mô hình hồi quy tuyến tính bội có dạng:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon.$$

Trong bài toán phân cứng, một mô hình phù hợp với mục tiêu dự báo PRP có thể viết là:

$$PRP = \beta_0 + \beta_1 MYCT + \beta_2 MMIN + \beta_3 MMAX + \beta_4 CACH + \beta_5 CHMIN + \beta_6 CHMAX + \varepsilon.$$

Trong bài toán điểm số, một mô hình dự báo G3 có thể viết là:

$$G3 = \beta_0 + \beta_1 G1 + \beta_2 G2 + \beta_3 studytime + \beta_4 failures + \beta_5 absences + \beta_6 paid + \beta_7 sex + \varepsilon.$$

Khi diễn giải hệ số hồi quy trong mô hình bội, cần hiểu theo nghĩa giữ các biến còn lại không đổi. Nếu $\beta_j > 0$, biến X_j có xu hướng làm tăng giá trị dự báo của Y . Nếu $\beta_j < 0$, biến X_j có xu hướng làm giảm giá trị dự báo của Y .

1.2.7 Đánh giá mô hình hồi quy: phần dư, R^2 , adjusted R^2 , p -value và F -statistic

Phần dư tại quan sát thứ i được tính bởi:

$$e_i = y_i - \hat{y}_i.$$

Phần dư cho biết mô hình dự báo lệch bao nhiêu so với giá trị thực tế. Nếu mô hình phù hợp, phần dư nên phân tán ngẫu nhiên quanh 0 và không tạo thành xu hướng rõ rệt^[4:8].




Figure 1.2.8: Minh họa residual plot với phần dư phân tán quanh 0

Hệ số xác định R^2 cho biết tỷ lệ biến thiên của biến phụ thuộc được mô hình giải thích:

$$R^2 = 1 - \frac{SSE}{SSTO}.$$

Adjusted R^2 là phiên bản hiệu chỉnh của R^2 , có xét đến số biến trong mô hình:

$$R_a^2 = 1 - \left(\frac{n-1}{n-p} \right) \left(\frac{SSE}{SSTO} \right).$$

Trong hồi quy bội, adjusted R^2 thường được dùng khi so sánh các mô hình có số lượng biến giải thích khác nhau, vì R^2 thông thường có xu hướng không giảm khi thêm biến mới^[6;7].

Trong bảng kết quả hồi quy của R, mỗi hệ số thường đi kèm với một p -value. Nếu p -value nhỏ hơn mức ý nghĩa, chẳng hạn 0.05, ta có cơ sở thống kê để xem hệ số đó khác 0. F -statistic được dùng để kiểm tra ý nghĩa tổng thể của mô hình, với giả thuyết không rằng tất cả hệ số góc đều bằng 0^[7;11].

Một cách trực quan khác để đánh giá mô hình là so sánh giá trị thực tế với giá trị dự báo. Nếu mô hình dự báo tốt, các điểm sẽ nằm gần đường chéo $y = \hat{y}$.




Figure 1.2.9: Minh họa biểu đồ giá trị thực tế so với giá trị dự báo

1.2.8 Một số hàm R thường dùng

Trong báo cáo này, R được sử dụng để đọc dữ liệu, xử lý dữ liệu, thống kê mô tả, vẽ biểu đồ, tính tương quan và xây dựng mô hình hồi quy. Các hàm dưới đây là những hàm cơ bản, thường gặp trong quy trình phân tích hai bộ dữ liệu^[2;10;11].

Hàm	Ý nghĩa sử dụng
<code>read.csv()</code>	Đọc dữ liệu từ tệp CSV vào R. Hàm này thường được dùng ở bước đầu tiên khi làm việc với dữ liệu bảng.
<code>summary()</code>	Tóm tắt nhanh dữ liệu. Với biến số, kết quả thường gồm min, Q1, median, mean, Q3 và max. Với biến phân loại, kết quả thường là số lượng quan sát theo từng mức.
<code>mean()</code>	Tính trung bình của một biến định lượng.
<code>median()</code>	Tính trung vị của một biến định lượng.
<code>sd()</code>	Tính độ lệch chuẩn mẫu.
<code>var()</code>	Tính phương sai mẫu.
<code>quantile()</code>	Tính các phân vị của dữ liệu, thường dùng để lấy Q_1 , median và Q_3 .
<code>table()</code>	Lập bảng tần số hoặc bảng chéo cho biến định tính.
<code>prop.table()</code>	Chuyển bảng tần số thành bảng tỷ lệ.
<code>hist()</code>	Vẽ histogram cho biến định lượng.
<code>boxplot()</code>	Vẽ boxplot, thường dùng để phát hiện ngoại lai hoặc so sánh nhiều nhóm.
<code>plot()</code>	Vẽ đồ thị cơ bản trong R, thường dùng để tạo scatter plot giữa hai biến định lượng.
<code>abline()</code>	Thêm đường thẳng vào đồ thị, chẳng hạn đường hồi quy hoặc đường tham chiếu $y = x$.
<code>cor()</code>	Tính hệ số tương quan, mặc định là tương quan Pearson.
<code>lm()</code>	Ước lượng mô hình hồi quy tuyến tính.
<code>summary(lm())</code>	Hiển thị kết quả chi tiết của mô hình hồi quy, gồm hệ số, sai số chuẩn, t -statistic, p -value, R^2 , adjusted R^2 và F -statistic.
<code>predict()</code>	Tạo giá trị dự báo từ mô hình đã ước lượng.

Table 1.2.1: Một số hàm R thường dùng trong phân tích dữ liệu

Ví dụ một quy trình phân tích cơ bản trong R có thể được viết như sau:

```
data <- read.csv("student-mat.csv")

summary(data$G3)
mean(data$G3)
```

```
median(data$G3)
sd(data$G3)

hist(data$G3)
boxplot(G3 ~ sex, data = data)

plot(data$G2, data$G3)
cor(data$G2, data$G3)

model <- lm(G3 ~ G1 + G2 + studytime + failures + absences, data = data)
summary(model)

pred <- predict(model)
plot(data$G3, pred)
abline(0, 1)
```




Figure 1.2.10: Một luồng thao tác điển hình trong R cho phân tích và hồi quy

Nhìn chung, các hàm R trên tương ứng trực tiếp với quy trình phân tích của báo cáo. Với bộ Computer Hardware Dataset, các hàm thống kê mô tả và biểu đồ giúp khảo sát MYCT, MMIN, MMAX, CACH và PRP trước khi hồi quy. Với bộ Student Performance Dataset, các hàm tương tự giúp phân tích G1, G2, G3, absences và so sánh điểm theo các nhóm như sex, paid, studytime hoặc failures. Sau bước mô tả và trực quan hóa, hàm `lm()` được dùng để xây dựng mô hình, còn `summary()` và `predict()` hỗ trợ đánh giá và dự báo.

1.2.9 Mô tả các biến số được sử dụng trong chương 3

Hiệu suất của một hệ thống máy tính không chỉ phụ thuộc vào một linh kiện đơn lẻ mà là kết quả của sự phối hợp chặt chẽ giữa các thành phần kiến trúc phần cứng cốt lõi. Trong đó, tốc độ chu kỳ máy (Machine Cycle Time), không gian lưu trữ bộ nhớ chính, số lượng kênh truyền và đặc biệt là dung lượng bộ nhớ đệm (Cache) đóng vai trò then chốt trong việc giảm độ trễ và tối ưu hóa quá trình tính toán. Nói cách khác, máy tính vận hành mạnh hay yếu phụ thuộc rất



lớn vào các giới hạn vật lý này. Vì vậy, trong chương này sẽ phân tích nhằm tìm hiểu các thông số kỹ thuật quyết định đến hiệu quả hoạt động của hệ thống phần cứng. Tập dữ liệu gốc được cung cấp bao gồm 10 biến. Tuy nhiên, trong đó chứa biến là tên dòng máy (Model Name) không mang lại giá trị trong các phép tính toán học. Để thuận tiện cho việc thống kê, phân tích tương quan và đánh giá, nhóm đã chọn lọc và loại bỏ các biến định tính này, chỉ giữ lại các biến định lượng liên quan trực tiếp đến nội dung nghiên cứu nhằm tập trung khai thác dữ liệu hiệu quả và chính xác hơn. Cụ thể, 9 biến số sẽ sử dụng được liệt kê dưới bảng sau:

Table 1.2.2: Danh sách các biến liên quan đến hiệu năng tổng quát

Tên biến	Diễn giải thuộc tính	Loại biến	Mô tả chi tiết
VendorName	Tên nhà cung cấp	Rời rạc	Tên nhà cung cấp các mẫu phần cứng.
MYCT	Tốc độ chu kỳ máy	Liên tục	Thời gian chu kỳ máy, đại diện cho thời gian cần thiết để bộ vi xử lý thực hiện một lệnh cơ bản (đơn vị: nanosecond - ns).
MMIN	Dung lượng bộ nhớ chính tối thiểu	Liên tục	Dung lượng bộ nhớ chính tối thiểu được cài đặt hoặc hỗ trợ trên hệ thống (đơn vị: KB).
MMAX	Dung lượng bộ nhớ chính tối đa	Liên tục	Dung lượng bộ nhớ chính tối đa mà kiến trúc của hệ thống có thể mở rộng và hỗ trợ (đơn vị: KB).
CACH	Dung lượng bộ nhớ đệm (Cache)	Liên tục	Bộ nhớ đệm tốc độ cao nằm trong hoặc rất gần bộ vi xử lý, lưu trữ các dữ liệu và lệnh thường xuyên sử dụng để giảm thiểu độ trễ khi truy xuất từ RAM (đơn vị: KB).
CHMIN	Số lượng kênh truyền dữ liệu tối thiểu	Liên tục	Số lượng kênh truyền dữ liệu tối thiểu (đơn vị: kênh).
CHMAX	Số lượng kênh truyền dữ liệu tối đa	Liên tục	Số lượng kênh truyền dữ liệu tối đa mà hệ thống có thể hỗ trợ (đơn vị: kênh).
PRP	Hiệu năng tương đối theo công bố thực tế	Liên tục	Chỉ số hiệu năng tương đối của hệ thống được nhà sản xuất công bố chính thức.
ERP	Hiệu năng tương đối theo ước lượng	Liên tục	Chỉ số hiệu năng tương đối được ước lượng và dự báo thông qua các mô hình toán học.

Table 1.2.3: Danh sách các biến liên quan đến hiệu năng tổng quát trong bộ Computer Hardware Dataset ở chương 3

Chương 2

Hoạt động 2 - THỐNG KÊ MÔ TẢ VÀ TRỰC QUAN HÓA DỮ LIỆU

2.1 Thông số cần chuẩn bị

2.1.1 Thống kê mô tả

Là quá trình thu thập, tổng hợp và xử lý dữ liệu để biến đổi dữ liệu thành thông tin. Trong đề tài này, các chỉ tiêu như trung bình, độ lệch chuẩn cùng với các biểu đồ trực quan được sử dụng để đánh giá tổng quan về điểm số học sinh và các yếu tố ảnh hưởng.

2.1.1.1 Các đặc trưng đo lường xu hướng trung tâm và độ phân tán

1. Xu hướng trung tâm

Trung bình (Mean): là đại lượng thường được sử dụng nhất để đo giá trị trung tâm của dữ liệu. Với một mẫu cỡ n , trung bình mẫu được xác định như sau:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Trung vị (Median): là giá trị nằm ở vị trí chính giữa của dữ liệu mẫu khi đã được sắp xếp theo thứ tự. Trung vị không bị ảnh hưởng bởi các giá trị ngoại lai (outliers). Nếu $n = 2k + 1$ (số lẻ), trung vị là giá trị ở vị trí chính giữa $Med = x_{k+1}$. Nếu $n = 2k$ (số chẵn), trung vị là trung bình cộng của hai giá trị giữa $Med = \frac{x_k + x_{k+1}}{2}$.

2. Độ phân tán

Phương sai (Variance): là trung bình của bình phương độ lệch các giá trị so với trung bình. Phương sai phản ánh độ phân tán hay sự biến thiên của dữ liệu. Phương sai của mẫu được tính bởi:

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

Độ lệch tiêu chuẩn (Standard deviation): được dùng để đo sự biến thiên, biểu diễn sự biến thiên xung quanh trung bình. Độ lệch chuẩn của mẫu có công thức:

$$S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}}$$

3. Các thước đo vị trí

Tứ phân vị (Quartiles): là các điểm chia dữ liệu đã sắp xếp thành bốn phần bằng nhau. Cụ thể:

- Tứ phân vị thứ nhất (Q_1): là trung vị của nửa dưới (các giá trị nhỏ hơn hoặc bằng Q_2).
- Tứ phân vị thứ hai (Q_2): chính là trung vị của toàn bộ mẫu.

- Tứ phân vị thứ ba (Q_3): là trung vị của nửa trên (các giá trị lớn hơn hoặc bằng Q_2).

Khoảng tứ phân vị (Interquartile Range): là một đại lượng thống kê đo lường mức độ phân tán của dữ liệu bằng cách xác định phạm vi giữa tứ phân vị thứ ba (Q_3) và tứ phân vị thứ nhất (Q_1).

$$IQR = R_Q = Q_3 - Q_1$$

Điểm ngoại lai (Outliers): là các giá trị sẽ nằm ngoài vùng khoảng giới hạn ($Q_1 - 1.5 \times IQR$, $Q_3 + 1.5 \times IQR$).

2.1.2 Mô hình tuyến tính bội

Là một kỹ thuật thống kê được sử dụng để mô hình hóa (model) và dự báo (predict) giá trị của một biến phụ thuộc (dependent variable, hay biến tiêu chí) dựa trên giá trị của một hoặc nhiều biến độc lập (independent variables, hay biến dự báo). Hồi quy mang tính phi đối xứng: giả định một chiều tác động (thường là nhân quả, mặc dù bản thân mô hình không thể chứng minh điều đó) từ biến độc lập đến biến phụ thuộc.

Khi mô hình sử dụng nhiều hơn một biến độc lập, nó được gọi là **Hồi quy tuyến tính bội (Multiple Linear Regression)**. Phương trình hồi quy tuyến tính bội có dạng tổng quát:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \epsilon_i$$

Trong đó:

- Y_i : Giá trị của biến phụ thuộc
- X_{ki} : Giá trị của biến độc lập
- β_0 : Hệ số chặn của tổng thể
- β_k : Hệ số góc của tổng thể
- ϵ_i : Sai số ngẫu nhiên (hoặc nhiễu), tuân theo giả định phân phối chuẩn với trung bình bằng 0 và phương sai không đổi ($\epsilon_i \sim N(0, \sigma^2)$)




Figure 2.1.1: Mối quan hệ giữa biến X và Y trong hồi quy tuyến tính

2.2 Phân tích dữ liệu và xây dựng mô hình

2.2.1 Đọc dữ liệu

Dữ liệu được nhập từ file điểm “*diem_so.csv*” bằng phần mềm R. Với các biến đầu vào bao gồm G1 (điểm thi học kỳ 1), G2 (điểm thi học kỳ 2) và G3 (điểm cuối khóa). Ngoài ra, dữ liệu còn bao gồm các biến liên quan như thời gian tự học trên tuần, số lần không qua môn, số lần nghỉ học, việc tham gia các lớp học thêm và giới tính học sinh.

```
1 data_raw <- read.csv("diem_so.csv")
2 data <- data_raw[, c("G1", "G2", "G3", "studytime", "failures", "absences",
  "paid", "sex")]
```

2.2.2 Làm sạch dữ liệu

Dữ liệu được kiểm tra và loại bỏ các giá trị thiếu (Not Available - NA) nhằm đảm bảo tính đầy đủ. Các giá trị không hợp lý như điểm số âm cũng bị loại bỏ bằng cách đặt điều kiện $G1 \geq 0$, $G2 \geq 0$, $G3 \geq 0$.

```
1 apply(is.na(data), 2, sum)
2 data <- na.omit(data)
3 data <- data[data$G1 >= 0, ]
4 data <- data[data$G2 >= 0, ]
5 data <- data[data$G3 >= 0, ]
```

	row.names	G1	G2	G3	studyt.me	failures	absences	paid	sex
1	1	5	6	6	2	0	6	no	F
2	3	7	8	10	2	3	10	yes	F
3	4	15	14	15	3	0	2	yes	F
4	5	6	10	10	2	0	4	yes	F
5	7	12	12	11	2	0	0	no	M
6	8	6	5	6	2	0	6	no	F
7	10	14	15	15	2	0	0	yes	M
8	11	10	8	9	2	0	0	yes	F
9	12	10	12	12	3	0	4	no	F
10	13	14	14	14	1	0	2	yes	M
11	14	10	10	11	2	0	2	yes	M
12	15	14	16	16	3	0	0	no	M
13	16	14	14	14	1	0	4	no	F
14	17	13	14	14	3	0	6	yes	F
15	18	8	10	10	2	0	4	no	F
16	19	6	5	5	1	3	16	no	M
17	20	8	10	10	1	0	4	yes	M
18	21	13	14	15	2	0	0	no	M
19	22	12	15	15	1	0	0	yes	M
20	23	15	15	16	2	0	2	no	M
21	24	13	13	12	2	0	0	no	M
22	25	10	9	8	3	0	2	yes	F
23	26	6	9	8	1	2	14	yes	F
24	27	12	12	11	1	0	2	yes	M
25	28	15	16	15	1	0	4	yes	M
26	29	11	11	11	2	0	4	no	M
27	30	10	12	11	2	0	16	yes	M
28	31	9	11	12	2	0	0	yes	M
29	32	17	16	17	2	0	0	no	M
30	33	17	16	16	2	0	0	no	M
31	34	8	10	12	2	0	0	no	M
32	35	12	14	15	1	0	0	yes	M
33	36	8	7	6	1	0	0	no	F
34	37	15	16	18	3	0	2	no	M
35	38	15	16	15	3	0	7	no	M
36	39	12	12	11	3	0	2	yes	F
37	40	14	13	13	1	0	8	yes	F
38	41	7	10	11	2	1	25	no	F
39	42	12	12	12	1	0	8	no	M
40	43	19	18	18	2	0	2	no	M
41	44	8	8	11	1	0	0	no	M
42	45	10	10	9	2	1	14	no	F

Figure 2.2.1: Kết quả sau khi lọc

2.2.3 Làm rõ dữ liệu

1. Chuyển đổi biến

Các biến dữ liệu được phân loại để phù hợp với phương pháp phân tích, cụ thể:

- Biến định lượng: G1, G2, G3, absences
- Biến định tính: sex, paid, studytime, failures

Những biến định tính được chuyển sang dạng *factor* để thuận tiện cho việc thống kê và xây dựng mô hình.

```
1 data$sex <- as.factor(data$sex)
2 data$paid <- as.factor(data$paid)
3 data$studytime <- as.factor(data$studytime)
4 data$failures <- as.factor(data$failures)
```

2. Thống kê mô tả

Đối với thống kê *mẫu*:

- Hàm `summary()` cung cấp tổng quan về toàn bộ tập dữ liệu.

```
1 print(summary(data))
```

```
=====
TỔNG QUAN DỮ LIỆU (summary):
      G1      G2      G3      studytime failures
Min.   : 3.00   Min.   : 0.00   Min.   : 0.00   1:105   0:307
1st Qu.: 8.00   1st Qu.: 9.00   1st Qu.: 8.00   2:194   1: 50
Median :11.00   Median :11.00   Median :11.00   3: 64    2: 17
Mean   :10.93   Mean   :10.72   Mean   :10.41   4: 27    3: 16
3rd Qu.:13.00   3rd Qu.:13.00   3rd Qu.:13.75
Max.   :19.00   Max.   :19.00   Max.   :20.00

absences      paid      sex
Min.   : 0.000   no :212   F:205
1st Qu.: 0.000   yes:178  M:185
Median : 4.000
Mean   : 5.715
3rd Qu.: 8.000
Max.   :75.000
=====
```

Figure 2.2.2: Kết quả sau khi print

Nhận xét: Sau khi làm sạch dữ liệu, không có giá trị thiếu (NA) và các thang điểm đều nằm trong giới hạn hợp lệ từ 0 đến 20. Chỉ số tứ phân vị cho thấy 50% lượng học sinh tập trung ổn định trong khoảng từ 8 đến 13 điểm xuyên suốt quá trình học.

Tiếp theo, ta tiến hành thống kê các biến **định lượng** (G1, G2, G3, absences) để đánh giá đặc điểm phân bố và mức độ biến động của từng biến.

- Vòng lặp for được sử dụng để lần lượt lấy từng biến và tính các chỉ tiêu thống kê mẫu như trung bình, trung vị, độ lệch chuẩn, phương sai, giá trị nhỏ nhất và lớn nhất, sau đó in kết quả ra màn hình.

```
1 cols_numeric <- c("G1", "G2", "G3", "absences")
2 for (col in cols_numeric) {
3   x <- data[[col]]
4   cat("\n", rep("=", 50), "\n", sep = "")
5   cat("PHÂN TÍCH BIẾN:", toupper(col), "\n")
6   cat(" - Trung bình (mean): ", round(mean(x), 2), "\n")
7   cat(" - Trung vị (median): ", round(median(x), 2), "\n")
8   cat(" - Độ lệch chuẩn (sd): ", round(sd(x), 2), "\n")
9   cat(" - Phương sai (var): ", round(var(x), 2), "\n")
10  cat(" - Giá trị nhỏ nhất (min): ", min(x), "\n")
11  cat(" - Giá trị lớn nhất (max): ", max(x), "\n")
12 }
```

```
=====
PHÂN TÍCH BIẾN: G1
- Trung bình (mean):      10.93
- Trung vị (median):      11
- Độ lệch chuẩn (sd):     3.29
- Phương sai (var):       10.83
- Giá trị nhỏ nhất (min): 3
- Giá trị lớn nhất (max): 19

=====
PHÂN TÍCH BIẾN: G2
- Trung bình (mean):      10.72
- Trung vị (median):      11
- Độ lệch chuẩn (sd):     3.74
- Phương sai (var):       13.97
- Giá trị nhỏ nhất (min): 0
- Giá trị lớn nhất (max): 19

=====
PHÂN TÍCH BIẾN: G3
- Trung bình (mean):      10.41
- Trung vị (median):      11
- Độ lệch chuẩn (sd):     4.57
- Phương sai (var):       20.88
- Giá trị nhỏ nhất (min): 0
- Giá trị lớn nhất (max): 20

=====
PHÂN TÍCH BIẾN: ABSENCES
- Trung bình (mean):      5.72
- Trung vị (median):      4
- Độ lệch chuẩn (sd):     8.03
- Phương sai (var):       64.55
- Giá trị nhỏ nhất (min): 0
- Giá trị lớn nhất (max): 75
```

Figure 2.2.3: Kết quả thống kê của biến định lượng

Nhận xét: Điểm trung bình có xu hướng giảm nhẹ qua các kỳ (từ 10.93 xuống 10.41), nhưng phương sai tăng mạnh từ 10.83 lên 20.88, cho thấy sự phân hóa học lực ngày càng lớn. Riêng biến số ngày nghỉ (absences) có độ phân tán cực cao (var = 64.55), phản ánh sự tồn tại của các trường hợp nghỉ học bất thường.

Để thống kê các biến **định tính** (sex, paid, studytime, failures) nhằm xác định phân bố của các nhóm trong dữ liệu, từ đó nhận biết nhóm nào chiếm tỷ lệ cao và đặc điểm chung của tập dữ liệu:

- Ta sử dụng hàm `table()` để đếm tần số xuất hiện của từng nhóm và hàm `prop.table()` để tính tỷ lệ tương ứng. Kết quả được in ra màn hình bằng hàm `print()`.

```
1 cat("\n---- Tần số và tỷ lệ: Giới tính (sex) ----\n")
2 print(table(data$sex))
3 print(prop.table(table(data$sex)))
4
5 cat("\n---- Tần số và tỷ lệ: Học thêm (paid) ----\n")
6 print(table(data$paid))
7 print(prop.table(table(data$paid)))
8
9 cat("\n---- Tần số và tỷ lệ: Thời gian tự học (studytime) ----\n")
```



```
10 print(table(data$studytime))
11 print(prop.table(table(data$studytime)))
12
13 cat("\n---- Tần số và tỷ lệ: Số lần trượt môn (failures) ----\n")
14 print(table(data$failures))
15 print(prop.table(table(data$failures)))
```

```
---- Tần số và tỷ lệ: Giới tính (sex) ----
  F  M
205 185

  F      M
0.525641 0.474359

---- Tần số và tỷ lệ: Học thêm (paid) ----
 no yes
212 178

  no      yes
0.5435897 0.4564103

---- Tần số và tỷ lệ: Thời gian tự học (studytime) ----
  1  2  3  4
105 194 64 27

  1      2      3      4
0.26923077 0.49743590 0.16410256 0.06923077

---- Tần số và tỷ lệ: Số lần trượt môn (failures) ----
  0  1  2  3
307 50 17 16

  0      1      2      3
0.78717949 0.12820513 0.04358974 0.04102564
```

Figure 2.2.4: Kết quả thống kê của biến định tính

Nhận xét: Cơ cấu mẫu khá cân bằng với 52,6% nữ và 54,4% không đi học thêm. Đa số học sinh có nền tảng tốt khi gần 79% chưa từng trượt môn và một nửa duy trì thời gian tự học ở mức ổn định.

3. Đồ thị

Đồ thị **Histogram** cho phép quan sát phân phối của các biến điểm số, số lần nghỉ học và số lần trượt môn, từ đó so sánh sự khác biệt giữa các biến.

- Ta sử dụng hàm `hist()` để vẽ biểu đồ histogram cho các biến G1, G2 và G3 nhằm trực quan hóa phân phối điểm số này.

```
1 # --- Histogram: G1, G2, G3 (so sánh phân phối 3 biến điểm) ---
2 par(mfrow = c(1, 3))
```

```

3 hist(data$G1, main = "Phân phối Điểm
  HK1 (G1)", xlab = "G1", col = "salmon", border = "white")
4 hist(data$G2, main = "Phân phối Điểm
  HK2 (G2)", xlab = "G2", col = "gold", border = "white")
5 hist(data$G3, main = "Phân phối Điểm Cuối
  Kỳ (G3)", xlab = "G3", col = "skyblue", border = "white")
6 par(mfrow = c(1, 1))
7
8 # --- Histogram: Absences ---
9 hist(data$absences, main = "Phân phối Số ngày nghỉ (absences)", xlab =
  "Absences", col = "mediumpurple", border = "white")
10
11 # --- Barplot: Failures ---
12 barplot(table(data$failures), main = "Phân phối Số lần trượt
  môn (failures)", xlab = "Failures", ylab = "Số học sinh", col = "tomato")

```




Figure 2.2.5: Biểu đồ Histogram thể hiện phân phối điểm học kỳ 1 (G1), học kỳ 2 (G2) và điểm cuối kỳ (G3)




Figure 2.2.6: Biểu đồ Histogram thể hiện phân phối số ngày nghỉ học (absences)




Figure 2.2.7: Biểu đồ Histogram thể hiện phân phối số lần trượt môn (failures)

Nhận xét:

- Hình 2.2.5: Phân phối của G1, G2 và G3 có dạng tương đối đối xứng và tập trung chủ yếu ở khoảng điểm trung bình đến khá, cho thấy kết quả học tập của học sinh khá ổn định. Ngoài ra, phân phối của G2 và G3 có xu hướng tương đồng, gợi ý mối liên hệ giữa điểm các kỳ học.

- Hình 2.2.6: Biến absences có phân phối lệch phải, phần lớn học sinh có số ngày nghỉ thấp, tuy nhiên vẫn tồn tại một số giá trị lớn bất thường, cho thấy có sự xuất hiện của các giá trị ngoại lệ.
- Hình 2.2.7: Biến failures tập trung chủ yếu ở giá trị 0 và giảm dần ở các giá trị cao hơn, cho thấy đa số học sinh không bị trượt môn, chỉ một số ít có số lần trượt cao.

Đồ thị **Boxplot** được sử dụng để so sánh điểm G3 giữa các nhóm học sinh theo các yếu tố khác nhau, từ đó đánh giá mức độ ảnh hưởng đến kết quả học tập.

- Hàm `boxplot()` sẽ vẽ biểu đồ hộp thể hiện mối quan hệ giữa số lần trượt môn (failures) và điểm cuối kỳ (G3).

```
1 # --- Boxplot: Studytime vs G3 ---
2 boxplot(G3 ~ studytime, data = data, main = "Thời gian tự học vs Điểm
   G3", xlab = "Studytime", ylab = "Điểm G3", col = "orange")
3
4 # --- Boxplot: Failures vs G3 ---
5 boxplot(G3 ~ failures, data = data, main = "Số lần trượt môn vs Điểm
   G3", xlab = "Failures", ylab = "Điểm G3", col = "salmon")
6
7 # --- Boxplot: Paid vs G3 ---
8 boxplot(G3 ~ paid, data = data, main = "Học thêm (paid) vs Điểm
   G3", xlab = "Paid", ylab = "Điểm G3", col = "lightgreen")
9
10 # --- Boxplot: Sex vs G3 ---
11 boxplot(G3 ~ sex, data = data, main = "Giới tính vs Điểm
   G3", xlab = "Sex", ylab = "Điểm G3", col = "plum")
```




Figure 2.2.8: Biểu đồ Boxplot thể hiện sự phân bố điểm G3 theo thời gian tự học (trái) và số lần trượt môn (phải)




Figure 2.2.9: Biểu đồ Boxplot thể hiện sự phân bố điểm G3 theo việc học thêm (trái) và giới tính (phải)

Nhận xét:

- Hình 2.2.8 (trái): Có mối tương quan thuận giữa thời gian tự học và kết quả, học sinh dành nhiều thời gian nghiên cứu hơn thường đạt mức điểm trung vị cao hơn.
- Hình 2.2.8 (phải): Đây là yếu tố tác động tiêu cực nhất, số lần trượt môn tỷ lệ nghịch với điểm số, cho thấy mất nền tảng gây ảnh hưởng lớn đến kết quả cuối kỳ.
- Hình 2.2.9 (trái): Việc tham gia các lớp học thêm không tạo ra sự khác biệt có ý nghĩa thống kê về điểm số giữa hai nhóm đối tượng.
- Hình 2.2.9 (phải): Kết quả học tập có sự đồng đều giữa nam và nữ, không có sự chênh lệch đáng kể về năng lực dựa trên yếu tố giới tính.

Đồ thị **Scatter plot** giúp biểu diễn các cặp giá trị của hai biến để nhận biết xu hướng tăng hoặc giảm.

- Hàm `plot()` được dùng để vẽ biểu đồ phân tán thể hiện mối quan hệ giữa điểm học kỳ 2 (G2) và điểm cuối kỳ (G3), sau đó kết hợp hàm `abline()` cùng mô hình hồi quy tuyến tính để vẽ đường xu hướng lên biểu đồ.

```
1 # --- Scatter plot: Absences vs G3 ---
2 plot(data$absences, data$G3, main = "Số ngày nghỉ vs Điểm
   G3", xlab = "Absences", ylab = "Điểm
   G3", col = rgb(0.2, 0.4, 0.6, 0.5), pch = 19)
3 abline(lm(G3 ~ absences, data = data), col = "red", lwd = 2)
4
5 # --- Scatter plot: G1 vs G3 ---
6 plot(data$G1, data$G3, main = "Điểm HK1 (G1) vs Điểm cuối kỳ
   (G3)", xlab = "G1", ylab = "G3", col = rgb(0.2, 0.4, 0.6, 0.5), pch = 19)
7 abline(lm(G3 ~ G1, data = data), col = "red", lwd = 2)
8
9 # --- Scatter plot: G2 vs G3 ---
10 plot(data$G2, data$G3, main = "Điểm HK2 (G2) vs Điểm cuối kỳ
   (G3)", xlab = "G2", ylab = "G3", col = rgb(0.8, 0.4, 0, 0.5), pch = 19)
11 abline(lm(G3 ~ G2, data = data), col = "blue", lwd = 2)
```




Figure 2.2.10: Biểu đồ Scatter plot thể hiện mối quan hệ giữa số ngày nghỉ học (absences) và điểm cuối kỳ (G3)




Figure 2.2.11: Biểu đồ Scatter plot thể hiện mối quan hệ giữa điểm học kỳ 1 (G1) và điểm cuối kỳ (G3)




Figure 2.2.12: Biểu đồ Scatter plot thể hiện mối quan hệ giữa điểm học kỳ 2 (G2) và điểm cuối kỳ (G3)

Nhận xét:

- Hình 2.2.10: Mật độ dữ liệu tập trung dày đặc ở khoảng 0-20 ngày nghỉ nhưng trải rộng trên mọi mức điểm. Đường hồi quy có độ dốc rất thấp, cho thấy số ngày vắng mặt không phải là biến số có khả năng dự báo mạnh cho kết quả học tập cuối kỳ.
- Hình 2.2.11 và Hình 2.2.12: Cả hai biểu đồ đều thể hiện mối tương quan thuận tuyến tính mạnh mẽ với đường hồi quy dốc lên rõ rệt. Mật độ các điểm dữ liệu hội tụ sát đường thẳng dự báo, chứng minh rằng kết quả các học kỳ trước (đặc biệt là G2) là chỉ số có trọng số cao nhất và độ tin cậy lớn nhất để xác định điểm số cuối kỳ.

2.2.4 Mô hình hồi quy tuyến tính

Phân tích các yếu tố ảnh hưởng đến điểm cuối kỳ (G3). Mô hình được xây dựng với biến phụ thuộc là G3 và các biến độc lập bao gồm G1, G2, studytime, failures, absences, paid và sex.

- Ta sử dụng hàm `lm()` để thiết lập mối quan hệ tuyến tính giữa biến phụ thuộc (G3) và các biến độc lập.
- Tiếp theo dùng hàm `summary()` để hiển thị kết quả chi tiết của mô hình, bao gồm các hệ số hồi quy, với mức ý nghĩa p – value và hệ số xác định R^2 nhằm đánh giá độ phù hợp của mô hình.

```
1 model_BTL <- lm(G3 ~ G1 + G2 + studytime + failures + absences + paid + sex,
  data = data)
2 print(summary(model_BTL))
```

```
Call:
lm(formula = G3 ~ G1 + G2 + studytime + failures + absences +
    paid + sex, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-9.4399 -0.4333  0.2346  0.9714  3.6477

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.72846    0.44079  -3.921 0.000105 ***
G1           0.14226    0.05708   2.492 0.013118 *
G2           0.97610    0.04971  19.635 < 2e-16 ***
studytime2   -0.14921    0.24303  -0.614 0.539623
studytime3    0.04101    0.33099   0.124 0.901449
studytime4   -0.74757    0.42644  -1.753 0.080404 .
failures1    -1.04906    0.30682  -3.419 0.000697 ***
failures2    -0.77815    0.48943  -1.590 0.112687
failures3    -0.15340    0.51870  -0.296 0.767598
absences      0.04489    0.01230   3.648 0.000302 ***
paidyes       0.08596    0.20318   0.423 0.672491
sexM          0.26006    0.21060   1.235 0.217649
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.901 on 378 degrees of freedom
Multiple R-squared:  0.8319,    Adjusted R-squared:  0.827
F-statistic: 170 on 11 and 378 DF,  p-value: < 2.2e-16
```

Figure 2.2.13: Kết quả mô hình hồi quy tuyến tính

Phân tích các chỉ số kiểm định:

- Adjusted R-squared* đạt mức 0.827, đây là hệ số xác định hiệu chỉnh cho biết các biến độc lập trong mô hình giải thích được 82,7% sự biến thiên của điểm số G3 thực tế. Chỉ số này trên 0.8 là mức rất cao, khẳng định mô hình cực kỳ tin cậy.
- Chỉ số $\Pr(> |t|)$ hay (p – value) dùng để kiểm định ý nghĩa thống kê; theo quy ước, nếu giá trị này nhỏ hơn 0.05 (có dấu sao), biến đó thực sự có tác động đến điểm số.

- *Estimate* (Hệ số hồi quy) cho biết mức độ thay đổi của G3 khi biến độc lập thay đổi 1 đơn vị.

Nhận xét: Mô hình cho kết quả rất tốt khi giải thích được xấp xỉ 83% sự biến động của điểm số trong thực tế. Qua kết quả thực nghiệm, điểm học kỳ 2 (G2) và số lần trượt môn được xác định là những nhân tố ảnh hưởng quyết định ($p < 0.001$). Trong khi đó các yếu tố như giới tính hay học thêm không tạo ra sự khác biệt rõ rệt, cho thấy những đặc điểm này không tác động nhiều đến kết quả học tập của học sinh trong tập mẫu này.

2.2.5 Dự báo điểm học sinh mới

Dự báo là việc sử dụng mô hình đã xây dựng để ước lượng giá trị của biến phụ thuộc trong các trường hợp mới.

- Ta tiến hành tạo dữ liệu mới bằng hàm `data.frame()` với các giá trị giả định như sau: điểm số hai kỳ đầu lần lượt $G1 = 10$ và $G2 = 11$; quá trình học tập $studytime = 3$, $absences = 2$ và $failures = 0$; yếu tố khác như $sex = F$, $paid = yes$.
- Sau đó, chạy hàm `predict()` để thực hiện áp dụng hồi quy vào dữ liệu giả định để đưa ra kết quả dự báo cuối cùng.
- Hàm `round()` và `cat()` sẽ hỗ trợ làm tròn kết quả đến 2 chữ số thập phân và xuất dữ liệu ra báo cáo.

```
1 new_student <- data.frame(  
2   G1 = 10,  
3   G2 = 11,  
4   studytime = factor(3, levels = levels(data$studytime)),  
5   failures = factor(0, levels = levels(data$failures)),  
6   absences = 2,  
7   paid = factor("yes", levels = levels(data$paid)),  
8   sex = factor("F", levels = levels(data$sex))  
9 )  
10  
11 prediction <- predict(model_BTL, newdata = new_student)  
12  
13 cat("\n", rep("=", 50), "\n", sep = "")  
14 cat("DỰ BÁO ĐIỂM CUỐI KỲ (G3):\n")  
15 cat("Điểm G3 dự báo:", round(prediction, 2), "\n")
```

```
=====
DỰ BÁO ĐIỂM CUỐI KỲ (G3):
Điểm G3 dự báo: 10.65
```

Figure 2.2.14: Kết quả dự đoán điểm G3

So sánh điểm thực tế với điểm dự báo

Để đánh giá trực quan độ chính xác của mô hình, ta sử dụng biểu đồ phân tán (Scatter Plot) với các hàm xử lý.

- Cụ thể, hàm `predict(model_BTL)` dùng để tính toán các giá trị dự báo dựa trên toàn bộ dữ liệu hiện có, kết quả này được đối chiếu trực tiếp với biến phụ thuộc thực tế (G3) để xác định độ chênh lệch.
- Lệnh `abline(0, 1)` là lệnh quan trọng nhất để vẽ đường hồi quy chuẩn tương ứng với phương trình $y = x$.

+ Hệ số 0: Đường thẳng đi qua gốc tọa độ.

+ Hệ số 1: Tạo độ dốc góc 45° , đại diện cho trạng thái lý tưởng khi điểm dự báo khớp hoàn toàn với điểm thực tế.

```
1 predicted_values <- predict(model_BTL)
2 actual_values <- data$G3
3
4 plot(actual_values, predicted_values,
5       main = "So sánh: Điểm thực tế vs Điểm dự báo",
6       xlab = "Điểm G3 thực tế",
7       ylab = "Điểm G3 dự báo",
8       col = rgb(0.2, 0.5, 0.8, 0.3), pch = 19
9 )
10 abline(0, 1, col = "red", lwd = 2)
```




Figure 2.2.15: Mô hình hồi quy thể hiện mối quan hệ giữa điểm thực tế và dự báo

Nhận xét: Dựa trên biểu đồ, các điểm dữ liệu thực tế hội tụ rất sát đường hồi quy ($y = x$), chứng tỏ sai số của mô hình là rất thấp và dự báo cực kỳ chuẩn xác. Kết quả dự báo đạt 10.65 nằm ngay tại khu vực có mật độ tập trung dày đặc nhất, cho thấy con số này hoàn toàn khớp với thực tế điểm số của học sinh qua các kỳ. Việc các điểm dữ liệu bám sát đường hồi quy chính là bằng chứng khẳng định mô hình hoạt động ổn định, phản ánh đúng quy luật: học sinh giữ vững phong độ ở các kỳ đầu thì điểm cuối kỳ sẽ xoay quanh mức dự báo đó.

Chương 3

Hoạt động 3 - THỐNG KÊ VÀ PHÂN TÍCH THÔNG SỐ HIỆU NĂNG PHẦN CỨNG MÁY TÍNH

3.1 Tổng quan về tập tài liệu

3.1.1 Mô tả tập dữ liệu

Trong bài báo cáo này, dữ liệu đầu vào được sử dụng là tập thông số kỹ thuật chi tiết của các hệ thống máy chủ và máy tính. Trọng tâm của bộ dữ liệu xoay quanh việc đánh giá năng lực xử lý phần cứng thông qua các đặc tính như chu kỳ máy, không gian bộ nhớ trong, và dung lượng bộ nhớ đệm. Việc khai thác các thuộc tính này làm cơ sở quan trọng để tiến hành các phép thống kê mô tả, phân tích tương quan và phục vụ mục đích xây dựng các mô hình dự báo hiệu năng tính toán.

Các thông tin tổng quan về bộ dữ liệu được tóm tắt như sau:

- **Tên bộ dữ liệu:** Computer Hardware Dataset.
- **Nguồn trích xuất dữ liệu:**
 - **Đơn vị cung cấp:** Dữ liệu gốc được thu thập bởi Phillip Ein-Dor và Jacob Feldmesser, hiện được lưu trữ công khai trên hệ thống UCI Machine Learning Repository.
 - **Mục tiêu ứng dụng:** Cung cấp nền tảng số liệu để kiểm định và đối chiếu sức mạnh phần cứng. Tập dữ liệu cho phép người nghiên cứu so sánh giữa hiệu năng công bố thực tế (PRP) và hiệu năng ước lượng (ERP) dựa trên kiến trúc linh kiện.
- **Quy mô và không gian mẫu:** Thông qua quá trình tiền xử lý và kiểm tra bằng ngôn ngữ lập trình R, tập dữ liệu được xác định bao gồm 10 chiều thuộc tính (biến số) và 209 mẫu quan trắc (tương ứng với 209 cấu hình máy tính khác nhau):

```
'data.frame': 209 obs. of 10 variables:
 $ VendorName: chr "adviser" "amdahl" "amdahl" "amdahl" ...
 $ ModelName : chr "32/60" "470v/7" "470v/7a" "470v/7b" ...
 $ MYCT : int 125 29 29 29 29 26 23 23 23 23 ...
 $ MMIN : int 256 8000 8000 8000 8000 8000 16000 16000 16000 32000 ...
 $ MMAX : int 6000 32000 32000 32000 16000 32000 32000 32000 64000 64000 ...
 $ CACH : int 256 32 32 32 32 64 64 64 64 128 ...
 $ CHMIN : int 16 8 8 8 8 16 16 16 32 ...
 $ CHMAX : int 128 32 32 32 16 32 32 32 32 64 ...
 $ PRP : int 198 269 220 172 132 318 367 489 636 1144 ...
 $ ERP : int 199 253 253 253 132 290 381 381 749 1238 ...
```

Figure 3.1.1: Thống kê số biến và giá trị quan trắc của file machine.csv

3.2 Phân tích dữ liệu

3.2.1 Đọc dữ liệu

```

1 column_names <- c("VendorName", "ModelName", "MYCT", "MMIN", "MMAX",
2                   "CACH", "CHMIN", "CHMAX", "PRP", "ERP")
3 main_data <- read.csv("machine.data", header = FALSE, col.names = column_names)
4 print("Số lượng dữ liệu khuyết:")
5 colSums(is.na(main_data))
6 head(main_data)

```

Bước 1: Đọc dữ liệu từ file CSV

Ta đọc dữ liệu từ file machine.data bằng hàm *read.csv()* trong R studio với các tham số:

- Header = FALSE: Xác định hàng đầu tiên của file data không phải là tên của cột dữ liệu.
- col.names = column_names: Gán các tên có trong column_names làm tên của các cột.

Bước 2: Làm sạch dữ liệu

Ta sử dụng hàm *colSums()* để tính tổng số lượng dữ liệu khuyết trên mỗi cột, kết quả trả về:

```

> colSums(is.na(main_data))#đánh dấu các ô có NA bằng true(số 1), sau đó colSums tính tổng tất cả số 1 đó ở mỗi cột và trả về
VendorName 0 ModelName 0 MYCT 0 MMIN 0 MMAX 0 CACH 0 CHMIN 0 CHMAX 0 PRP 0 ERP 0

```

Figure 3.2.1: Kết quả sau khi quét số lượng dữ liệu khuyết của file Main_data

Tổng mỗi cột đều bằng 0 tức là không tồn tại dữ liệu khuyết nên bỏ qua bước làm sạch dữ liệu.

Bước 3: Kiểm tra dữ liệu

Ta sử dụng hàm *head()* để hiển thị 6 dòng đầu của file main_data để kiểm tra dữ liệu có đúng cột hay chưa.

	VendorName	ModelName	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP	ERP
1	adviser	32/60	125	256	6000	256	16	128	198	199
2	amdahl	470v/7	29	8000	32000	32	8	32	269	253
3	amdahl	470v/7a	29	8000	32000	32	8	32	220	253
4	amdahl	470v/7b	29	8000	32000	32	8	32	172	253
5	amdahl	470v/7c	29	8000	16000	32	8	16	132	132
6	amdahl	470v/b	26	8000	32000	64	8	32	318	290

Figure 3.2.2: Bảng dữ liệu sau khi thêm tên cột dữ liệu (6 dòng đầu)

3.2.2 Thống kê mô tả

3.2.2.1 Thống kê biến liên tục


```
1 cont_cols <- c("MYCT", "MMIN", "MMAX", "CACH", "CHMIN", "CHMAX", "PRP")
2 t_summary_stats <- function(df, cols) {
3   ta.frame(
4     NN = apply(df[cols], 2, min),
5     Do_lech_chuan = apply(df[cols], 2, sd),
6     Trung_binh = apply(df[cols], 2, mean),
7     Trung_vi = apply(df[cols], 2, median),
8     GTLN = apply(df[cols], 2, max),
9     Q1 = apply(df[cols], 2, function(x) quantile(x, 0.25)),
10    Q3 = apply(df[cols], 2, function(x) quantile(x, 0.75))
11  )
12
13  ats_df <- get_summary_stats(main_data, cont_cols)
14  int("Thống kê biến liên tục:")
15  int(round(ats_df, 2))
16 }
```

Bước 1: Khai báo các cột dữ liệu liên tục

Ta sử dụng hàm `c()` để tạo một vector tên là `cont_cols` chứa tên của các cột dữ liệu của các biến liên tục cần tính.

Bước 2: Viết hàm để tính thông số thống kê của các biến liên tục

Ta sử dụng hàm `function()` với 2 tham số đầu vào là `df` (*dataframe hay bảng dữ liệu*) và `cols` (*danh sách các cột cần tính*) để tiến hành tạo hàm tính toán thông số thống kê:

- **Hàm `data.frame()`:** Tạo một bảng dữ liệu mới để lưu trữ và trình bày các đại lượng thống kê tính toán.
- **Hàm `apply()`:** Thực hiện tính toán cho toàn bộ không gian ma trận dữ liệu, với 3 tham số đầu vào gồm: bảng dữ liệu hoặc ma trận; hướng quét với 1 là ngang và 2 là dọc; phép toán dùng để xử lý bảng hoặc ma trận đầu vào.
- **Hàm `quantile()`:** Tính toán tứ phân vị thứ nhất và thứ ba, do hàm cần 2 tham số đầu vào nên sử dụng hàm `function()` làm trung gian để đưa dữ liệu vào rồi tính toán các tứ phân vị tương ứng.

Bước 3: Tính toán thống kê và hiển thị

Ta sử dụng hàm `get_summary_stats()` vừa định nghĩa để tính toán thống kê file `main_data`, ta được bảng sau:

Table 3.2.1: Bảng thống kê biến liên tục

Biến	GTNN	Độ lệch chuẩn	Trung bình	Trung vị	GTLN	Q1	Q3
MYCT	17	260.26	203.82	110	1500	50	225
MMIN	64	3878.74	2867.98	2000	32000	768	4000
MMAX	64	11726.56	11796.15	8000	64000	4000	16000
CACH	0	40.63	25.21	8	256	0	32
CHMIN	0	6.82	4.70	2	52	1	6
CHMAX	0	26.00	18.27	8	176	5	24
PRP	6	160.83	105.62	50	1150	27	113

Ta tiến hành thống kê các giá trị trung bình, trung vị, độ lệch chuẩn, giá trị lớn nhất, giá trị nhỏ nhất và các tứ phân vị cho bảy biến liên tục sau: MYCT, MMIN, MMAX, CACH, CHMIN, CHMAX, và PRP. Dựa trên kết quả trong bảng thống kê, ta có các nhận xét như sau:

Thông số trung bình của một hệ thống máy tính theo tập dữ liệu:

- Chu kỳ máy (MYCT): 203.82 ns (nano giây).
- Bộ nhớ trong tối thiểu (MMIN): 2867.98 KB.
- Bộ nhớ trong tối đa (MMAX): 11796.15 KB.
- Bộ nhớ đệm (CACH): 25.21 KB.
- Số kênh tối thiểu (CHMIN): 4.70 kênh.
- Số kênh tối đa (CHMAX): 18.27 kênh.
- Hiệu suất tương đối (PRP): 105.62 điểm.

Chu kỳ máy (MYCT): Từ 17 - 1500

- $Q1 = 50$.
- Median = 110.
- $Q3 = 225$.
- Độ lệch chuẩn = 260.26.
- Phân phối lệch phải. Mức dao động lớn do độ lệch chuẩn (260.26) vượt mức trung bình (203.82).

Bộ nhớ trong tối thiểu (MMIN): từ 64 - 32000 KB

- $Q1 = 768 \text{ KB}$.
- $\text{Median} = 2000 \text{ KB}$.
- $Q3 = 4000 \text{ KB}$.
- $\text{Độ lệch chuẩn} = 3878.74 \text{ KB}$.
- Phân phối lệch phải. Dữ liệu phân tán rất mạnh ở phần đuôi, do khoảng cách từ $Q3$ (4000 KB) đến GTLN (32000 KB) là cực kỳ lớn.

Bộ nhớ trong tối đa (MMAX): từ 64 - 64000 KB

- $Q1 = 4000 \text{ KB}$.
- $\text{Median} = 8000 \text{ KB}$.
- $Q3 = 16000 \text{ KB}$.
- $\text{Độ lệch chuẩn} = 11726.56 \text{ KB}$.
- Phân phối lệch phải: Giá trị lớn nhất gấp 4 lần $Q3$ cho thấy sự xuất hiện của các hệ thống có cấu hình đột biến.

Bộ nhớ đệm (CACH): từ 0 - 256 KB

- $Q1 = 0 \text{ KB}$.
- $\text{Median} = 8 \text{ KB}$.
- $Q3 = 32 \text{ KB}$.
- $\text{Độ lệch chuẩn} = 40.63 \text{ KB}$.
- Phân phối lệch phải: Có ít nhất 25% số lượng máy tính trong tập mẫu hoàn toàn không được trang bị bộ nhớ đệm ($Q1 = 0 \text{ KB}$).

Số kênh tối thiểu (CHMIN): từ 0 - 52 kênh

- $Q1 = 1 \text{ kênh}$.
- $\text{Median} = 2 \text{ kênh}$.
- $Q3 = 6 \text{ kênh}$.
- $\text{Độ lệch chuẩn} = 6.82 \text{ kênh}$.
- Phân phối lệch phải: Phần lớn máy tính có số kênh tối thiểu rất thấp ($Q3$ chỉ bằng 6 kênh).

Số kênh tối đa (CHMAX): từ 0 - 176 kênh

- $Q1 = 5 \text{ kênh}$.

- Median = 8 kênh.
- Q3 = 24 kênh.
- Độ lệch chuẩn = 26.00 kênh.
- Phân phối lệch phải: Dữ liệu tập trung ở mức thấp, nhưng có sự tồn tại của các giá trị ngoại lệ kéo dài đến 176 kênh.

Hiệu suất tương đối (PRP): từ 6 - 1150 điểm

- Q1 = 27 điểm.
- Median = 50 điểm.
- Q3 = 113 điểm.
- Độ lệch chuẩn = 160.83 điểm.
- Phân phối lệch phải: Hiệu suất trung bình bị kéo lệch lên cao (105.62 điểm) so với trung vị (50 điểm) do ảnh hưởng của một số ít các máy tính siêu hiệu năng ở đuôi phân phối.

Tóm lại, khi đối chiếu các trung vị (Median) này với các giá trị trung bình, ta nhận thấy mức trung bình đang bị kéo lên cao hơn rất nhiều so với trung vị ở tất cả các biến. Điều này chứng tỏ:

- Các thông số đại diện (Trung bình) không hoàn toàn phản ánh đúng cấu hình của đại đa số máy tính trên thị trường.
- Thị trường có sự phân hóa mạnh với đặc trưng phân phối lệch phải. Phần lớn máy tính tập trung ở phân khúc cấu hình thấp và trung bình, trong khi một số ít các hệ thống máy chủ (mainframe) siêu hiệu năng sở hữu các thông số vượt trội đã kéo giãn toàn bộ giá trị trung bình của tập dữ liệu.

3.2.3 Thống kê biến rời rạc

```
1 print("Số lượng máy tính theo hãng sản xuất (Top 10):")
2 ad(sort(table(main_data$VendorName), decreasing = TRUE), 10)
```

```
[1] "Số lượng máy tính theo hãng sản xuất (Top 10):"
> head(sort(table(main_data$VendorName), decreasing = TRUE), 10)
      ibm      nas honeywell      ncr      sperry      siemens      amdahl      cdc burroughs      dg
      32       19       13       13       13       12       9       9       8       7
```

Figure 3.2.3: Kết quả thống kê số lượng máy tính theo hãng sản xuất

Nhận xét: Vị trí top 1 thuộc về ibm với 32 hệ thống máy tính. Con số này tạo ra khoảng cách rất lớn gần gấp đôi so với vị trí thứ hai là nas với 19 máy và vượt xa phần còn lại. Điều này cho thấy ibm là nhà cung cấp chiếm thị phần áp đảo nhất trong tập mẫu khảo sát.

3.3 Đồ thị

3.3.1 Tiền xử lí dữ liệu

```
1 main_data_long <- main_data %>%  
2 select(MYCT, MMIN, MMAX, CACH, CHMIN, CHMAX, PRP) %>%  
3 pivot_longer(cols = c("MYCT", "MMIN", "MMAX", "CACH", "CHMIN", "CHMAX"),  
4               names_to = "Variable",  
5               values_to = "Value")
```

Bước 1: Chọn lọc dữ liệu

Ta sử dụng hàm *select()* để chọn lọc các dữ liệu cần thiết cho biểu đồ và đồ thị là: Hiệu suất (PRP) và 6 thông số phản ứng (MYCT, MMIN, MMAX, CACH, CHMIN, CHMAX).

Bước 2: Xoay cấu trúc dữ liệu

Ta sử dụng hàm *pivot_longer()* để chuyển vị khung dữ liệu từ hàng ngang sang hàng dọc với mốc là PRP ứng với từng cấu hình máy tương ứng để thuận tiện cho vẽ đồ thị và bảng biểu:

Trước

MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP	ERP
125	256	6000	256	16	128	198	199
29	8000	32000	32	8	32	269	253
29	8000	32000	32	8	32	220	253
29	8000	32000	32	8	32	172	253
29	8000	16000	32	8	16	132	132
26	8000	32000	64	8	32	318	290
23	16000	32000	64	16	32	367	381
23	16000	32000	64	16	32	489	381
23	16000	64000	64	16	32	636	749
23	32000	64000	128	32	64	1144	1238
400	1000	3000	0	1	2	38	23
400	512	3500	4	1	6	40	24
60	2000	8000	65	1	8	92	70
50	4000	16000	65	1	8	138	117
350	64	64	0	1	4	10	15
200	512	16000	0	4	32	35	64
167	524	2000	8	4	15	19	23
143	512	5000	0	7	32	28	29
143	1000	2000	0	5	16	31	22
110	5000	5000	142	8	64	120	124
143	1500	6300	0	5	32	30	35
143	3100	6200	0	5	20	33	39
143	2300	6200	0	6	64	61	40
110	3100	6200	0	6	64	76	45
320	128	6000	0	1	12	23	28
320	512	2000	4	1	3	69	21
320	256	6000	0	1	6	33	28
320	256	3000	4	1	3	27	22
320	512	5000	4	1	5	77	28
320	256	5000	4	1	6	27	27
25	1310	2620	131	12	24	274	102
25	1310	2620	131	12	24	368	102
50	2620	10480	30	12	24	32	74
50	2620	10480	30	12	24	63	74

→

Sau

PRP	Variable	Value
198	MYCT	125
198	MMIN	256
198	MMAX	6000
198	CACH	256
198	CHMIN	16
198	CHMAX	128
269	MYCT	29
269	MMIN	8000
269	MMAX	32000
269	CACH	32
269	CHMIN	8
269	CHMAX	32
220	MYCT	29
220	MMIN	8000
220	MMAX	32000
220	CACH	32
220	CHMIN	8
220	CHMAX	32
172	MYCT	29
172	MMIN	8000
172	MMAX	32000
172	CACH	32
172	CHMIN	8
172	CHMAX	32
132	MYCT	29
132	MMIN	8000
132	MMAX	16000
132	CACH	32
132	CHMIN	8
132	CHMAX	16
318	MYCT	26
318	MMIN	8000
318	MMAX	32000
318	CACH	64

Figure 3.3.1: Kết quả sau khi xoay cấu trúc dữ liệu

3.3.2 Đồ thị Scatters

```

1 p_scatter <- ggplot(main_data_long, aes(x = Value, y = PRP)) +
2   om_point(alpha = 0.5, color = "steelblue") +
3   cet_wrap(~ Variable, scales = "free_x", ncol = 3) +
4   theme_minimal() +
5   bs(title = "Scatter Plot: PRP so với các thông số khác")
6   int(p_scatter)

```




Figure 3.3.2: Biểu đồ scatter giữa PRP và các thông số phần cứng

Nhận xét:

- Các thông số MMIN, MMAX, CACH, CHMIN, và CHMAX đều thể hiện xu hướng đồng biến với PRP. Khi giá trị của các thông số này tăng lên, hiệu suất máy tính (PRP) cũng có xu hướng tăng theo.
- Riêng hai biến về bộ nhớ trong là MMAX (Bộ nhớ tối đa) và MMIN (Bộ nhớ tối thiểu) cho thấy mối tương quan rõ nét và mạnh mẽ nhất. Các điểm dữ liệu bám khá sát theo đường chéo hướng lên. Điều này khẳng định dung lượng bộ nhớ là yếu tố dự báo mang tính quyết định lớn đến hiệu suất hệ thống.
- Biến MYCT (Chu kỳ máy) là thông số duy nhất có đồ thị đi ngược lại với phần còn lại. Khi MYCT tăng, hiệu suất PRP lại giảm đột ngột và tiệm cận về gần mức 0. Điều này

hoàn toàn đúng, trong thực tế thì chu kỳ máy càng ngắn tức là thời gian xử lý một lệnh càng ít, tốc độ tính toán càng nhanh, dẫn đến điểm hiệu suất càng cao.

3.3.3 Đồ thị Histogram

```
1 all_vars_long <- main_data %>%  
2   select(all_of(cont_cols)) %>%  
3   vlonger(cols = everything(), names_to = "Variable", values_to = "Value")  
4   write_csv(all_vars_long, "du_lieu_cho_histogram_va_boxplot.csv", row.names =  
5     FALSE)  
6  
7 hist <- ggplot(all_vars_long, aes(x = Value)) +  
8   geom_histogram(bins = 20, fill = "skyblue", color = "black", alpha = 0.7) +  
9   facet_wrap(~ Variable, scales = "free", ncol = 3) +  
10  theme_minimal() +  
11  labs(title = "Histogram của các thông số cấu hình", x = "Giá trị", y = "Tần  
    suất")  
12 print(hist)
```

Khác với dữ liệu của đồ thị Scatters, dữ liệu của Histogram nhận luôn PRP làm biến nên dùng hàm *select()* lọc các dữ liệu theo *cont_cols* để đưa vào vẽ đồ thị:




Figure 3.3.3: Đồ thị Histogram của 7 biến sau chọn lọc

Nhận xét:

- Toàn bộ 7 biến đều có chung một dạng phân phối là lệch phải rất mạnh. Sự phân bố này phản ánh đúng thực tế của thị trường máy tính ngày xưa: Khoảng 75% - 80% mẫu quan sát trong tập dữ liệu là các dòng máy tính cấu hình thấp hoặc phổ thông.
- Ở phần đuôi dữ liệu không trải đều mà bị đứt gãy cho thấy thị trường không có sự liên mạch. Phân khúc siêu cao cấp như là một thế giới hoàn toàn khác, sở hữu các thông số nhảy vọt chứ không tăng tịnh tiến từ phân khúc tầm trung lên.
- Đồ thị PRP phản ánh hệ quả của 6 đồ thị phần cứng: Vì đa số linh kiện đều ở mức thấp, nên điểm hiệu suất PRP cũng tập trung dày đặc ở dải điểm dưới 300 (cột cao nhất dao động quanh mức 80 máy). Số lượng hệ thống đạt điểm PRP trên 300 là cực kỳ hiếm hoi và chỉ đếm trên đầu ngón tay.

3.3.4 Đồ thị Boxplot

```
1 p_box <- ggplot(all_vars_long, aes(y = Value)) +
2   om_boxplot(fill = "lightgreen", color = "darkgreen", alpha = 0.6) +
3   cet_wrap(~ Variable, scales = "free_y", ncol = 3) + theme_minimal() +
4   bs(title = "Boxplot kiểm tra điểm ngoại lai (Outliers)", y = "Giá trị")+
5   eme(axis.text.x = element_blank(), axis.ticks.x = element_blank())
6   int(p_box)
```




Figure 3.3.4: Đồ thị Boxplot của 7 biến sau chọn lọc

Nhận xét:

- Cấu trúc chung của cả 7 đồ thị là 50% dữ liệu trung tâm bị nén rất hẹp ở dải giá trị thấp. Ngoài ra đường trung vị nằm sát về phía tứ phân vị thứ nhất, điều này phản ánh phần lớn

các quan sát trong tập dữ liệu bị dồn ép ở phân khúc có thông số kỹ thuật thấp và hiệu suất thấp. Sự chênh lệch giá trị giữa các quan sát ở phân khúc này là không lớn.

- Trong khi dải dữ liệu từ trung vị xuống mức thấp nhất rất ngắn, thì phạm vi từ trung vị lên mức giá trị cao nhất (giới hạn trên của râu biểu đồ) lại kéo dài hơn rất nhiều. Điều này cho thấy sự phân hóa bắt đầu xuất hiện mạnh mẽ khi cấu hình máy tính tăng lên, các hệ thống ở phân khúc tầm trung có thông số rời rạc và chênh lệch nhau lớn hơn nhiều so với phân khúc phổ thông.
- Sự xuất hiện dày đặc của các điểm dữ liệu ngoại lai vượt xa giới hạn phân bố thông thường ở biên trên. Hiện tượng này xảy ra với toàn bộ 7 biến, đặc biệt rõ rệt ở hiệu suất PRP, dung lượng bộ nhớ tối đa MMAX và bộ nhớ đệm CACH. Điều này xác nhận tập dữ liệu chứa một nhóm nhỏ các cỗ máy cấu hình cao với các thông số nhảy vọt hoàn toàn so với mặt bằng chung của thị trường. Ở chiều ngược lại, hoàn toàn không ghi nhận giá trị ngoại lai nào ở biên dưới.

3.4 Mô hình hồi quy tuyến tính

3.4.1 Kiểm định mối tương quan

```
1 cor_matrix <- cor(main_data[cont_cols])  
2 int("Ma trận tương quan giữa các biến:")  
3 int(round(cor_matrix, 3))
```

Ta sử dụng hàm `cor()` để đánh giá mức độ và chiều hướng tương quan tuyến tính giữa biến phụ thuộc (điểm hiệu suất PRP) và các biến độc lập (thông số phần cứng).

	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP
MYCT	1.000	-0.336	-0.379	-0.321	-0.301	-0.251	-0.307
MMIN	-0.336	1.000	0.758	0.535	0.517	0.267	0.795
MMAX	-0.379	0.758	1.000	0.538	0.561	0.527	0.863
CACH	-0.321	0.535	0.538	1.000	0.582	0.488	0.663
CHMIN	-0.301	0.517	0.561	0.582	1.000	0.548	0.609
CHMAX	-0.251	0.267	0.527	0.488	0.548	1.000	0.605
PRP	-0.307	0.795	0.863	0.663	0.609	0.605	1.000

Figure 3.4.1: Hệ số tương quan giữa các biến với nhau

Nhận xét:

- Nhóm biến có tương quan thuận rất mạnh: Dung lượng bộ nhớ tối đa MMAX ($r = 0.863$) và Bộ nhớ tối thiểu MMIN ($r = 0.795$). Đây được xác định là hai biến dự báo có trọng số quan trọng nhất đối với hiệu suất hệ thống.
- Nhóm biến có tương quan thuận mức độ khá: CACH ($r = 0.663$), CHMIN ($r = 0.609$), và CHMAX ($r = 0.605$).
- Biến duy nhất có tương quan nghịch: Chu kỳ máy MYCT ($r = -0.307$).

3.4.2 Lọc giá trị ngoại lai

```
1 Q1 <- quantile(main_data$PRP, 0.25)
2   <- quantile(main_data$PRP, 0.75)
3 R_val <- Q3 - Q1
4 lower_lim <- Q1 - 1.5 * IQR_val
5 upper_lim <- Q3 + 1.5 * IQR_val
6 clean_data <- main_data[main_data$PRP >= lower_lim & main_data$PRP <= upper_lim,
  ]
```

Ta làm sạch dữ liệu đối với biến phụ thuộc PRP bằng phương pháp Khoảng tứ phân vị (Interquartile Range - IQR):

Bước 1: Tính toán tứ phân vị

Xác định cụ thể biến PRP từ *tập dữ liệu* **main_data**, thông qua hàm *quantile()* để xác định tứ phân vị thứ nhất *Q1* và thứ ba *Q3* của dữ liệu PRP.

Bước 2: Tính toán khoảng IQR và giới hạn

Tính toán khoảng $IQR = Q3 - Q1$, sau đó tính tiếp hàng rào giới hạn:

- Giới hạn dưới ($lower_lim$) = $Q1 - 1.5 \times IQR$
- Giới hạn trên ($upper_lim$) = $Q3 + 1.5 \times IQR$

Bước 3: Trích xuất dữ liệu sau khi lọc giá trị ngoại lai

Tất cả các cấu hình nào có giá trị PRP thỏa mãn điều kiện lớn hơn hoặc bằng giới hạn dưới và bé hơn hoặc bằng giới hạn trên thì sẽ được sử dụng làm dữ liệu đầu vào cho mô hình hồi quy.

```
'data.frame': 186 obs. of 10 variables:
 $ VendorName: chr "adviser" "amdahl" "amdahl" "amdahl" ...
 $ ModelName : chr "32/60" "470v/7a" "470v/7b" "470v/7c" ...
 $ MYCT : int 125 29 29 29 400 400 60 50 350 200 ...
 $ MMIN : int 256 8000 8000 8000 1000 512 2000 4000 64 512 ...
 $ MMAX : int 6000 32000 32000 16000 3000 3500 8000 16000 64 16000 ...
 $ CACH : int 256 32 32 32 0 4 65 65 0 0 ...
 $ CHMIN : int 16 8 8 8 1 1 1 1 1 4 ...
 $ CHMAX : int 128 32 32 16 2 6 8 8 4 32 ...
 $ PRP : int 198 220 172 132 38 40 92 138 10 35 ...
 $ ERP : int 199 253 253 132 23 24 70 117 15 64 ...
```

Figure 3.4.2: Tập dữ liệu sau khi lọc giá trị ngoại lai

Có tất cả 186 cấu hình thỏa điều kiện.

3.5 Xây dựng mô hình hồi quy tuyến tính dự báo PRP

```
1 model_BTL <- lm(PRP ~ MYCT + MMIN + MMAX + CACH + CHMIN + CHMAX, data =
  clean_data)
2 t("KẾT QUẢ MÔ HÌNH HỒI QUY TUYẾN TÍNH:\n\n")
3 int(summary(model_BTL))
```

Mô hình dự đoán PRP được xây dựng với PRP là biến phụ thuộc và các biến MYCT, MMIN, MMAX, CACH, CHMIN và CHMAX là biến độc lập thông qua:

- Sử dụng hàm *lm()* để thiết lập mối quan hệ tuyến tính giữa PRP với các biến còn lại.
- Sử dụng hàm *summary()* để hiển thị kết quả chi tiết của mô hình như hệ số Estimate, p-value, R-squared, F-statistic,...

```
Call:
lm(formula = PRP ~ MYCT + MMIN + MMAX + CACH + CHMIN + CHMAX,
    data = clean_data)

Residuals:
    Min       1Q   Median       3Q      Max
-77.503 -11.682   0.039   7.948  72.525

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.2414458   4.2914465   0.522  0.602103
MYCT        -0.0005595   0.0075215  -0.074  0.940787
MMIN         0.0065718   0.0013174   4.988  1.43e-06 ***
MMAX         0.0032622   0.0003250  10.039 < 2e-16 ***
CACH         0.4664755   0.0726603   6.420  1.19e-09 ***
CHMIN        2.2737061   0.6186708   3.675  0.000314 ***
CHMAX        0.0855713   0.1111626   0.770  0.442442
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 24.19 on 179 degrees of freedom
Multiple R-squared:  0.7893,    Adjusted R-squared:  0.7823
F-statistic: 111.8 on 6 and 179 DF,  p-value: < 2.2e-16
```

Figure 3.5.1: Kết quả chi tiết của mô hình hồi quy tuyến tính

Phân tích các chỉ số kiểm định:

- **F-statistic và mức ý nghĩa tổng thể:** Mô hình đạt giá trị F-statistic là 111.8 với p -value $< 2.2 \times 10^{-16}$. Giá trị p -value này nhỏ hơn rất nhiều so với mức ý nghĩa chuẩn 0.05, khẳng định phương trình hồi quy vừa xây dựng hoàn toàn có ý nghĩa thống kê tổng thể. Tập hợp các biến độc lập thực sự có khả năng giải thích sự biến thiên của biến phụ thuộc.
- **Adjusted R-squared:** Hệ số xác định hiệu chỉnh đạt mức 0.7823 cho biết các thông số phân cứng trong mô hình giải thích được 78.23% sự biến thiên của điểm hiệu suất PRP thực tế. Mức chỉ số tiệm cận 0.8 là rất cao đối với dữ liệu thực nghiệm, khẳng định mô hình có độ tin cậy lớn.
- **Pr(> |t|):** Dùng để kiểm định ý nghĩa thống kê của từng nhân tố độc lập. Theo quy ước, nếu giá trị này nhỏ hơn 0.05 (có đánh dấu sao), biến đó thực sự có tác động đến điểm số:
 - Các biến MMIN, MMAX, CACH, và CHMIN đều có p -value < 0.001 (đánh dấu ***), chúng tỏ chúng có tác động mạnh mẽ và ý nghĩa thống kê rõ rệt.
 - Ngược lại, biến MYCT (0.9407) và CHMAX (0.4424) có giá trị p -value > 0.05 , cho thấy chúng không có ý nghĩa thống kê trong việc dự báo ở phương trình này.

- **Hệ số Estimate:** Cho biết mức độ thay đổi của biến phụ thuộc PRP khi một biến độc lập thay đổi 1 đơn vị, trong điều kiện các biến khác giữ nguyên. Ví dụ: Hệ số của CACH là 0.4664, nghĩa là khi dung lượng bộ nhớ đệm tăng thêm 1 KB, điểm hiệu suất dự kiến của máy tính sẽ tăng thêm xấp xỉ 0.47 điểm.
- **Residual standard error (Sai số chuẩn của phần dư):** Residual standard error đạt 24.19, tức là mức độ sai lệch dự báo trung bình so với thực tế.

Nhận xét: Phương trình hồi quy tuyến tính ban đầu đã phản ánh rất sát thực tế cấu trúc phần cứng khi giải thích được thành công 78.23% sự phân hóa về mặt hiệu suất giữa các hệ thống máy tính. Nhóm cốt lõi gồm dung lượng RAM (MMIN, MMAX), bộ nhớ đệm (CACH) và bảng thông cơ sở (CHMIN) đều cho thấy mức độ tác động cực kỳ mạnh mẽ và tích cực đến hiệu suất. Trong khi đó, các yếu tố như chu kỳ xử lý máy (MYCT) hay số lượng kênh tối đa (CHMAX) không tạo ra sự khác biệt rõ rệt về mặt thống kê, cho thấy những đặc điểm này không tác động nhiều đến tốc độ chung của hệ thống trong tập mẫu này.

3.6 Dự báo hiệu suất và so sánh

3.6.1 Dự báo điểm hiệu suất máy mới

```
1 new_machine <- data.frame(  
2 MYCT = 100,  
3 MMIN = 256,  
4 MMAX = 6000,  
5 CACH = 256,  
6 CHMIN = 16,  
7 CHMAX = 128  
8  
9 ediction <- predict(model_BTL, newdata = new_machine)  
10 int(paste("Điểm PRP dự báo:", round(prediction, 2)))
```

Giả sử công ty nhập về một lô máy tính mới với thông số cụ thể: **MYCT=100; MMIN=256; MMAX=6000; CACH=256; CHMIN=16; CHMAX=128**

Tạo dữ liệu mới bằng hàm `data.frame()` với các thông số trên, sau đó dùng hàm `predict()` để thực hiện áp dụng mô hình hồi quy `model_BTL` vào dữ liệu giả định để đưa ra dự báo:




Figure 3.6.1: Kết quả dự báo PRP của mô hình

3.6.2 So sánh hiệu suất PRP thực tế và dự báo

```

1 predicted_values <- predict(model_BTL)
2 tual_values <- clean_data$PRP
3
4 ot_data <- data.frame(ThucTe = actual_values, DuBao = predicted_values)
5
6 regression <- ggplot(plot_data, aes(x = ThucTe, y = DuBao)) +
7   geom_point(color = "steelblue", alpha = 0.7, size = 2.5) +
8   geom_abline(intercept = 0, slope = 1, color = "red", linewidth = 1.2) +
9   theme_minimal() +
10  labs(title = "So sánh: PRP Thực tế vs Dự báo",
11        x = "Điểm PRP Thực tế",
12        y = "Điểm PRP Dự báo")
13
14 int(p_regression)

```

Ta sử dụng biểu đồ Scatter Plot để đánh giá trực quan độ chính xác của mô hình:

Bước 1: Tự dự đoán lại điểm hiệu suất PRP của tập dữ liệu

Sử dụng hàm `predict(model_BTL)` không có tham số `newdata` sẽ tự động lấy tập dữ liệu `clean_data` để tự dự đoán, kết quả lưu vào `predicted_values`. Trích suất dữ liệu thực tế ban đầu của điểm hiệu suất PRP bằng lệnh `clean_data$PRP`, kết quả lưu vào `actual_values`. Sử dụng hàm `data.frame(ThucTe = actual_values, DuBao = predicted_values)` để ghép 2 tập dữ liệu lại thành 2 cột để vẽ biểu đồ.

Bước 2: Vẽ biểu đồ

Hàm `geom_abline(intercept = 0, slope = 1, color = "red", linewidth = 1.2)` dùng để vẽ một đường hồi quy chuẩn tương ứng với phương trình $y = x$, với:

- `intercept = 0`: Đường thẳng đi qua gốc tọa độ, nếu bằng một số a nào đó bất kì thì tương đương với phương trình $y = x + a$.

- slope = 1: Tạo độ dốc góc 45° , đại diện cho trạng thái lý tưởng khi điểm dự báo khớp hoàn toàn với điểm thực tế, nếu bằng một số b nào đó bất kì thì tương đương với phương trình $y = bx$.




Figure 3.6.2: Mô hình hồi quy thể hiện mối quan hệ giữa điểm thực tế và dự báo

Nhận xét:

- **Tại vùng hiệu suất thấp và trung bình (Điểm PRP < 100):** Các điểm dữ liệu màu xanh hội tụ rất sát và bám dọc theo đường hồi quy chuẩn $y = x$. Điều này chứng tỏ sai số của phương trình tại phân khúc này là rất thấp. Mô hình hoạt động cực kỳ ổn định và dự báo đặc biệt chuẩn xác đối với các hệ thống máy tính có cấu hình phổ thông.
- **Hạn chế của mô hình OLS:** Khi xét ở vùng hiệu suất cao (Điểm PRP thực tế > 150), biểu đồ cho thấy các điểm dữ liệu bắt đầu có xu hướng phân tán rộng hơn và nằm lệch xuống phía dưới đường hồi quy chuẩn (hiện tượng Underprediction). Điều này phản ánh một đặc tính thực tế của hồi quy tuyến tính: mô hình có xu hướng dự báo thấp hơn so với thực tế đối với những hệ thống siêu máy tính có sức mạnh vượt trội mang tính đột biến.
- **Khả năng ứng dụng thực tiễn:** Kết quả dự báo cho máy tính thử nghiệm (đạt 190.19 điểm) rơi vào khu vực có mật độ điểm dữ liệu bắt đầu phân tán hơn. Tuy nhiên, việc phân



lớn các quan sát cốt lõi vẫn bám sát đường hồi quy chuẩn chính là bằng chứng khẳng định mô hình đã đi đúng quy luật: sự gia tăng về dung lượng RAM và bộ nhớ đệm chắc chắn sẽ kéo theo sự gia tăng tương ứng về điểm hiệu suất thực tế.

Chương 4

KẾT LUẬN VÀ KIẾN NGHỊ

Trong kỷ nguyên dữ liệu số, Xác suất Thống kê không chỉ thuần túy là một nhánh của toán học ứng dụng mà đã trở thành lăng kính tư duy bắt buộc đối với mọi kỹ sư để chuyển hóa dữ liệu thô thành tri thức định lượng. Thông qua bài tập lớn này, vai trò trọng yếu của XSTK trong kỹ thuật một lần nữa được khẳng định rõ nét khi các bạn sinh viên thuộc nhóm 5 áp dụng thành công các công cụ thống kê mô tả, phân tích tương quan và mô hình hóa vào thực tiễn. Quá trình xử lý hai tập dữ liệu khác biệt về bản chất đã chứng minh rằng phương pháp Bình phương tối thiểu thông thường cung cấp một khung diễn giải tuyến tính trực quan, cho phép đánh giá chính xác trọng số của từng tham số cấu thành hệ thống. Hơn thế nữa, bài tập lớn là minh chứng thực tế cho thấy tư duy thống kê giúp sinh viên vượt qua các phán đoán cảm tính, nhận diện đúng các giới hạn hệ thống và đưa ra các quyết định tối ưu hóa dựa trên bằng chứng toán học vững chắc.

Đối với hoạt động phân tích hệ thống dữ liệu giáo dục (Student Performance Dataset), ưu điểm nổi bật của phương pháp hồi quy tuyến tính là khả năng bóc tách và định lượng hóa độ trễ của thành tích học tập, thể hiện qua việc mô hình giải thích được khoảng 83% sự biến thiên của điểm số cuối kỳ chủ yếu thông qua kết quả của các học kỳ trước và số lượng lỗi hỏng kiến thức tích lũy. Mặc dù cấu trúc mô hình có tính diễn giải cao, hỗ trợ tốt cho các nhà quản lý giáo dục trong việc cảnh báo sớm rủi ro, hệ thống phân tích hiện tại vẫn bộc lộ một số nhược điểm nhất định do bị ràng buộc bởi giả định tuyến tính khắt khe. Các yếu tố mang tính can thiệp như thời gian tự học hay việc học thêm chưa thể hiện rõ tác động trong phương trình hồi quy, gợi ý về sự tồn tại của hiện tượng đa cộng tuyến hoặc các biến ẩn chưa được định lượng đầy đủ. Để phát triển hướng nghiên cứu này, các mô hình trong tương lai cần được nâng cấp bằng cách tích hợp thêm các thuật toán học máy phi tuyến như Mô hình rừng cây (Random Forest) để bắt được các tương tác phức tạp trong tâm lý học đường, đồng thời mở rộng không gian đặc trưng

thông qua việc thu thập thêm các biến số về phương pháp giảng dạy nhằm mang lại một bức tranh đánh giá toàn diện hơn.

Hoạt động đánh giá hiệu năng phần cứng máy tính (Computer Hardware Dataset) đã phát huy thế mạnh khi chứng minh bằng toán học hiện tượng thất cổ chai von Neumann, xác nhận rằng dung lượng bộ nhớ chính và bộ nhớ đệm đóng vai trò quyết định đối với sức mạnh tính toán thay vì chỉ phụ thuộc vào chu kỳ máy. Dù mô hình Bình phương tối thiểu thông thường mô phỏng rất tốt hành vi của các hệ thống máy tính phổ thông với độ tin cậy đạt 78%, nhược điểm lớn nhất của phương pháp này lại bộc lộ rõ khi xử lý tập dữ liệu có độ lệch phải cực đoan. Việc cố gắng tối thiểu hóa sai số toàn cục đã khiến hệ thống dự báo vấp phải hiện tượng dự báo thấp hơn thực tế khi đối mặt với nhóm thiết bị siêu máy chủ có cấu hình đột biến. Nhằm khắc phục triệt để rào cản thuật toán này, hướng phát triển tối ưu cho bài toán phần cứng là áp dụng các phép biến đổi không gian đặc trưng như Logarit tự nhiên hoặc Box-Cox để ổn định phương sai trước khi huấn luyện. Kết hợp với việc ứng dụng các thuật toán hồi quy có hiệu chuẩn (Ridge, Lasso) để kiểm soát nhiễu đa cộng tuyến giữa các linh kiện, độ vững và khả năng khái quát hóa của hệ thống dự báo chắc chắn sẽ được nâng lên một tầm cao mới, đáp ứng trọn vẹn yêu cầu khắt khe của kỹ thuật máy tính hiện đại.

References

- [1] Paulo Cortez and Alice Maria Goncalves Silva. Using data mining to predict secondary school student performance. In *Proceedings of 5th Annual Future Business Technology Conference*, pages 5–12, Porto, Portugal, 2008.
- [2] Peter Dalgaard. *Introductory Statistics with R*. Springer, New York, 2 edition, 2008.
- [3] Phillip Ein-Dor and Jacob Feldmesser. Attributes of the performance of central processing units: A relative performance prediction model. *Communications of the ACM*, 30(4):308–317, 1987.
- [4] Andrew Gelman and Jennifer Hill. *Data Analysis Using Regression and Multi-level/Hierarchical Models*. Cambridge University Press, Cambridge, 2007.
- [5] Rob J. Hyndman and Yanan Fan. Sample quantiles in statistical packages. *The American Statistician*, 50(4):361–365, 1996.
- [6] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: With Applications in R*. Springer, New York, 2013.
- [7] Douglas C. Montgomery and George C. Runger. *Applied Statistics and Probability for Engineers*. John Wiley & Sons, Hoboken, NJ, 6 edition, 2014.
- [8] NIST/SEMATECH. Nist/sematech e-handbook of statistical methods. Technical report, National Institute of Standards and Technology, 2002. Accessed: 2026-04-30.
- [9] Karl Pearson. Mathematical contributions to the theory of evolution. iii. regression, heredity, and panmixia. *Philosophical Transactions of the Royal Society of London. Series A*, 187:253–318, 1896.
- [10] R Core Team. *An Introduction to R*. The R Project for Statistical Computing, 2026. Accessed: 2026-04-30.



- [11] R Core Team. *R Function Reference Manuals*. The R Project for Statistical Computing, 2026. Accessed: 2026-04-30.
- [12] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA, 1977.
- [13] UCI Machine Learning Repository. Computer hardware dataset. <https://archive.ics.uci.edu/ml/datasets/Computer+Hardware>, 1987. Accessed: 2026-04-30.
- [14] UCI Machine Learning Repository. Student performance dataset. <https://archive.ics.uci.edu/ml/datasets/Student+Performance>, 2008. Accessed: 2026-04-30.